Mục lục

1 Giới thiệu **1**

1.1 Bối cảnh và tính cấp thiết của đồ án 1

1.2 Vấn đề cần giải quyết 2

1.3 Mục tiêu của đồ án 2

1.4 Phạm vi và giới hạn của đồ án 3

1.4.1 Phạm vi nghiên cứu 3

1.4.2 Giới hạn nghiên cứu 3

1.5 Phương pháp nghiên cứu và cách tiếp cận 4

2 Cơ sở lý thuyết và tổng quan nghiên cứu **5**

2.1 Tổng quan các khái niệm liên quan 5

2.1.1 Khái niệm Customer Churn 5

2.1.2 Phân loại churn 6

2.1.3 Giá trị vòng đời khách hàng 6

2.1.4 Đặc điểm dữ liệu churn 6

2.1.5 Học máy trong dự báo churn 6

2.1.6 Dữ liệu mất cân bằng 6

2.1.7 Học kết hợp 7

2.1.8 Trí tuệ nhân tạo có thể giải thích 7

2.2 Tổng quan các nghiên cứu liên quan (2020–2025) 7

2.2.1 Nhận xét tổng hợp và câu hỏi nghiên cứu chung 10

2.3 Lý thuyết và mô hình được áp dụng 11

2.3.1 Lý thuyết Gradient Boosting 11

2.3.2 XGBoost 11

2.3.3 SMOTE 11

2.3.4 SHAP (Shapley Additive Explanations) 11

2.3.5 Các chỉ số đánh giá 12

3 Phương pháp thực hiện **12**

3.1 Tổng quan phương pháp nghiên cứu 12
3.2 Dữ liệu và tiêu chí lựa chọn 13
3.2.1 Mô tả tập dữ liệu 13
3.2.2 Mẫu dữ liệu thực tế 14
3.2.3 Lý do lựa chọn tập dữ liệu 15
3.3 Quy trình triển khai hệ thống 15
3.4 Tiền xử lý và khắc phục mất cân bằng dữ liệu 21
3.4.1 Chuẩn hóa đặc trưng bằng StandardScaler 21
3.4.2 Kỹ thuật SMOTE – giải quyết mất cân bằng nhãn 22
3.5 Đặc tả thuật toán XGBoost 23
3.5.1 Nền tảng lý thuyết: Gradient Boosting 23
3.5.2 Cơ chế tối ưu hóa hàm mất mát 25
3.5.3 Siêu tham số và chiến lược cấu hình 25
3.6 Chỉ số đánh giá hiệu suất mô hình 25
3.6.1 Tại sao Accuracy không phải là chỉ số phù hợp 25
3.6.2 Precision, Recall và F1-Score 26
3.6.3 Diện tích dưới đường cong ROC (AUC-ROC) 26
3.7 Thiết kế trí tuệ nhân tạo có thể giải thích (XAI với SHAP) 26
3.7.1 Vấn đề “hộp đen” trong học máy kinh doanh 26
3.7.2 Lý thuyết giá trị Shapley 26
3.8 Kiến trúc giao diện web 27
4 Kết quả và phân tích 27
4.1 Kết quả khám phá dữ liệu 27
4.1.1 Phân tích tổng quan phân phối nhãn 27
4.1.2 Phân tích biến độ tuổi 27
4.1.3 Phân tích biến giới tính 28
4.1.4 Phân tích các biến định lượng khác 29
4.2 Đánh giá hiệu suất mô hình 30
4.2.1 Kết quả huấn luyện và so sánh 30

4.2.2 Phân tích chi tiết báo cáo phân loại 30
4.2.3 So sánh hiệu suất trước và sau SMOTE 30
4.3 Phân tích SHAP – Giải thích mô hình 31
4.3.1 Phân tích tầm quan trọng đặc trưng toàn cục 31
4.3.2 Phân tích SHAP cục bộ cho khách hàng cụ thể 32
4.4 Kết quả triển khai giao diện web 33
4.4.1 Mô tả giao diện và tính năng 33
4.4.2 Đánh giá khả năng ứng dụng thực tiễn 35
5 Thảo luận 35
5.1 So sánh kết quả với mục tiêu ban đầu 35
5.2 Những điểm mạnh của đồ án 36
5.3 Những hạn chế của đồ án 36
5.4 Những phát hiện đáng chú ý 37
5.5 Hướng phát triển tương lai 38
6 Kết luận 38
6.1 Tổng kết các nội dung chính của nghiên cứu 38
6.2 Ý nghĩa khoa học và thực tiễn của đồ án 39
6.2.1 Ý nghĩa khoa học 39
6.2.2 Ý nghĩa thực tiễn 39
6.3 Hướng phát triển và nghiên cứu trong tương lai 40
6.4 Kiến nghị 41
7 Tài liệu tham khảo 42
8 Phụ lục 43
8.1 Danh mục hình ảnh 43
8.2 Danh mục mã nguồn 44
8.3 Tài liệu bổ trợ và liên kết công khai 44
8.4 Mã nguồn chi tiết 45

8.4.1 Tệp `3_train_model.py` – Pipeline huấn luyện XGBoost + SMOTE 45
8.4.2 Tệp `4_xai_shap.py` – Phân tích SHAP 46
8.5 Dữ liệu chi tiết – Kết quả thực nghiệm 48

DANH MỤC BẢNG

2.1 Tổng hợp các nghiên cứu liên quan về dự báo rời bỏ khách hàng (2020–2025) 8
3.1 Mô tả chi tiết các thuộc tính trong tập dữ liệu Churn Modelling 14
3.2 Mẫu dữ liệu từ tập Churn_Modelling.csv (5 bản ghi đầu tiên) 15
3.3 Bộ siêu tham số của mô hình XGBoost được sử dụng trong nghiên cứu . 25
4.1 Bảng so sánh hiệu suất các thuật toán dự đoán Customer Churn 30
4.2 Báo cáo phân loại chi tiết của mô hình XGBoost trên tập test 30
4.3 So sánh hiệu suất mô hình XGBoost trước và sau khi áp dụng SMOTE . 31
8.1 Danh mục hình ảnh trong nội dung chính của đồ án 43
8.2 Danh mục mã nguồn trong nội dung chính của đồ án 44
8.3 Danh mục tài liệu bổ trợ và liên kết công khai 44
8.4 Kết quả đánh giá mô hình – So sánh trước và sau SMOTE 48

DANH MỤC HÌNH ẢNH

3.1 Sơ đồ luồng dữ liệu của hệ thống dự đoán churn 16
3.2 Mã nguồn tệp `1_convert_to_json.py` – Giai đoạn thu thập và làm sạch dữ liệu 17
3.3 Mã nguồn tệp `2_eda_va_tien_xu_ly.py` – Giai đoạn EDA và tiền xử lý dữ liệu 18
3.4 Mã nguồn tệp `3_train_model.py` – Giai đoạn huấn luyện mô hình XGBoost 19
3.5 Mã nguồn tệp `4_xai_shap.py` – Giai đoạn phân tích XAI với SHAP . . 20
3.6 Mã nguồn tệp `app.py` – Giao diện web Streamlit Dashboard 21

3.7 Lưu đồ thuật toán huấn luyện mô hình XGBoost 24
4.1 Phân phối độ tuổi của khách hàng theo trạng thái rời bỏ 28
4.2 Tỷ lệ rời bỏ khách hàng theo giới tính 29
4.3 Phân tích tầm quan trọng của các đặc trưng thông qua biểu đồ SHAP Summary 31
4.4 Giao diện hệ thống dự báo rời bỏ khách hàng tích hợp mô hình AI 34

1. Giới thiệu

1.1. Bối cảnh và tính cấp thiết của đồ án

Trong kỷ nguyên chuyển đổi số, dữ liệu đã trở thành tài nguyên chiến lược của doanh nghiệp. Đặc biệt trong lĩnh vực thương mại điện tử, sự phát triển mạnh mẽ của Internet, thiết bị di động và thanh toán trực tuyến đã làm thay đổi toàn diện hành vi tiêu dùng. Khách hàng ngày nay có khả năng so sánh giá cả, chất lượng dịch vụ và trải nghiệm người dùng giữa nhiều nền tảng khác nhau chỉ trong vài phút, làm gia tăng đáng kể mức độ cạnh tranh giữa các doanh nghiệp.

Một trong những thách thức lớn nhất mà các doanh nghiệp thương mại điện tử phải đối mặt là hiện tượng Customer Churn – tức sự rời bỏ của khách hàng.

Nhiều nghiên cứu trong thập kỷ gần đây chỉ ra rằng chi phí thu hút một khách hàng mới cao hơn từ 5 đến 20 lần so với chi phí giữ chân một khách hàng hiện tại. Điều này đồng nghĩa với việc nếu doanh nghiệp không có chiến lược giữ chân khách hàng hiệu quả, chi phí marketing và quảng cáo sẽ tăng mạnh trong khi lợi nhuận không được đảm bảo. Bên cạnh đó, khách hàng trung thành thường có xu hướng chi tiêu nhiều hơn, ít nhạy cảm với giá và có khả năng giới thiệu thương hiệu cho người khác, tạo ra hiệu ứng lan truyền tích cực.

Trong bối cảnh đó, khả năng dự báo sớm nguy cơ rời bỏ khách hàng trở thành yếu tố mang tính chiến lược. Nếu doanh nghiệp có thể xác định được nhóm khách hàng có nguy cơ churn trước khi họ thực sự rời đi, các chiến lược can thiệp như khuyến mãi cá nhân hóa, chăm sóc khách hàng chủ động, hoặc cải thiện trải nghiệm dịch vụ có thể được triển khai kịp thời.

Sự phát triển của học máy và trí tuệ nhân tạo đã cung cấp những công cụ mạnh mẽ để xử lý và khai thác dữ liệu khách hàng ở quy mô lớn. Các thuật toán học máy có khả năng phát hiện các mẫu ẩn trong dữ liệu hành vi tiêu dùng mà các phương pháp thống kê truyền thống khó có thể nhận diện. Tuy nhiên, bên cạnh độ chính xác, các doanh nghiệp hiện đại còn đặt ra yêu cầu về tính minh bạch và khả năng giải thích mô hình, dẫn đến xu hướng kết hợp giữa mô hình dự báo mạnh và trí tuệ nhân tạo có thể giải thích (XAI).

Xuất phát từ bối cảnh thực tiễn và xu hướng nghiên cứu hiện đại, đề tài *"Xây dựng hệ thống dự báo rời bỏ khách hàng trong thương mại điện tử sử dụng XGBoost và SHAP Explainability"* được thực hiện nhằm giải quyết đồng thời ba vấn đề: độ chính xác, xử lý mất cân bằng dữ liệu và khả năng giải thích mô hình.

1.2. Vấn đề cần giải quyết

Mặc dù churn prediction đã được nghiên cứu trong nhiều lĩnh vực như viễn thông, ngân hàng và bảo hiểm, việc áp dụng trong thương mại điện tử vẫn tồn tại nhiều thách thức đặc thù.

Thứ nhất, dữ liệu churn thường mất cân bằng. Trong thực tế, tỷ lệ khách hàng rời bỏ thường thấp hơn nhiều so với khách hàng không rời bỏ. Điều này khiến mô hình dễ bị thiên lệch về lớp đa số, dẫn đến độ chính xác tổng thể cao nhưng khả năng phát hiện khách hàng rời bỏ (recall cho lớp churn) thấp.

Thứ hai, nhiều mô hình hiện đại có độ chính xác cao nhưng thiếu khả năng giải thích. Các mô hình như Gradient Boosting hoặc học sâu thường được coi là "hộp đen" (black-box). Trong môi trường doanh nghiệp, việc đưa ra quyết định dựa trên mô hình không thể giải thích rõ ràng có thể làm giảm mức độ tin cậy và khó được chấp nhận bởi nhà quản lý.

Thứ ba, khoảng cách giữa nghiên cứu và triển khai thực tế vẫn còn tồn tại. Nhiều nghiên cứu dừng lại ở mức đánh giá mô hình trên dữ liệu thí nghiệm mà chưa tích hợp vào hệ thống hỗ trợ ra quyết định trực quan cho doanh nghiệp.

Từ các vấn đề trên, bài toán nghiên cứu được đặt ra như sau: làm thế nào để xây dựng một hệ thống dự báo churn có độ chính xác cao, xử lý hiệu quả dữ liệu mất cân bằng và đồng thời cung cấp khả năng giải thích minh bạch cho từng dự đoán, có thể triển khai trong môi trường thương mại điện tử? Câu hỏi này sẽ được làm rõ và hoàn thiện hơn sau khi tổng hợp các nghiên cứu liên quan ở Chương 2.

1.3. Mục tiêu của đồ án

Để giải quyết vấn đề nghiên cứu đã nêu, đề tài đặt ra các mục tiêu cụ thể sau:

1. Phân tích đặc điểm dữ liệu churn trong thương mại điện tử.
2. Xây dựng pipeline xử lý dữ liệu bao gồm làm sạch, chuẩn hóa và mã hóa biến.
3. Áp dụng kỹ thuật SMOTE để xử lý mất cân bằng dữ liệu.
4. Huấn luyện mô hình XGBoost cho bài toán phân loại nhị phân.
5. Đánh giá mô hình dựa trên các chỉ số: Accuracy, Precision, Recall, F1-score, ROC-AUC.
6. Ứng dụng SHAP để phân tích tầm quan trọng đặc trưng và giải thích từng dự đoán cá nhân.
7. Xây dựng dashboard trực quan bằng Streamlit để hiển thị kết quả dự báo và biểu đồ SHAP.

Mục tiêu tổng quát của đề tài không chỉ là tối ưu độ chính xác mà còn hướng đến xây dựng một hệ thống có thể ứng dụng thực tế và hỗ trợ ra quyết định chiến lược.

1.4. Phạm vi và giới hạn của đồ án

1.4.1. Phạm vi nghiên cứu

- Tập trung vào bài toán phân loại nhị phân churn / non-churn.
- Sử dụng dữ liệu dạng bảng (tabular dataset).
- Áp dụng mô hình học máy truyền thống (ensemble learning).
- Tích hợp trí tuệ nhân tạo có thể giải thích ở mức giải thích mô hình cây.
- Triển khai giao diện minh họa phục vụ phân tích.

1.4.2. Giới hạn nghiên cứu

- Không sử dụng dữ liệu thời gian thực.
- Không triển khai trên hệ thống production.

- Không tích hợp học sâu tuần tự như RNN hoặc Transformer.
- Dữ liệu sử dụng mang tính mô phỏng.

1.5. Phương pháp nghiên cứu và cách tiếp cận

Nghiên cứu được triển khai theo 6 bước tuần tự:

Bước 1: Khám phá dữ liệu

- Phân tích phân phối biến.
- Kiểm tra dữ liệu thiếu.
- Phân tích tương quan.

Bước 2: Tiền xử lý dữ liệu

- Mã hóa biến phân loại.
- Chuẩn hóa dữ liệu số.
- Tách tập train/test.

Bước 3: Xử lý mất cân bằng

- Áp dụng SMOTE.
- So sánh hiệu suất trước và sau khi xử lý.

Bước 4: Huấn luyện mô hình

- Sử dụng XGBoost.
- Tối ưu siêu tham số cơ bản.
- Đánh giá bằng cross-validation.

Bước 5: Giải thích mô hình

- Tính SHAP values.

- Phân tích tầm quan trọng toàn cục.
- Phân tích giải thích cục bộ.

Bước 6: Triển khai giao diện

- Tích hợp mô hình vào Streamlit.
- Hiển thị bảng khách hàng.
- Hiển thị biểu đồ SHAP waterfall.

2. Cơ sở lý thuyết và tổng quan nghiên cứu

2.1. Tổng quan các khái niệm liên quan

2.1.1. Khái niệm Customer Churn

Customer Churn (rời bỏ khách hàng) là hiện tượng khách hàng ngừng sử dụng sản phẩm hoặc dịch vụ của doanh nghiệp trong một khoảng thời gian xác định. Trong môi trường có hợp đồng như viễn thông trả sau hoặc bảo hiểm, churn được xác định khi khách hàng chấm dứt hợp đồng. Tuy nhiên, trong môi trường thương mại điện tử, việc xác định churn phức tạp hơn vì không tồn tại ràng buộc pháp lý.

Trong thương mại điện tử, churn thường được xác định thông qua:

- Không phát sinh giao dịch trong một khoảng thời gian T.
- Không đăng nhập hoặc tương tác với hệ thống.
- Không mở email hoặc phản hồi chiến dịch marketing.

Do đặc thù không hợp đồng, churn trong thương mại điện tử mang tính hành vi nhiều hơn là hành chính, khiến bài toán dự báo trở nên khó khăn hơn và phụ thuộc nhiều vào phân tích dữ liệu hành vi người dùng.

2.1.2. Phân loại churn

Trong nghiên cứu học máy, churn prediction thường được mô hình hóa dưới dạng:

- Phân loại nhị phân: 0 = Không rời bỏ; 1 = Rời bỏ.
- Dự báo xác suất: mô hình dự đoán xác suất khách hàng churn trong tương lai.
- Dự báo thời điểm rời bỏ: áp dụng các mô hình survival analysis.

2.1.3. Giá trị vòng đời khách hàng

Giá trị vòng đời khách hàng (Customer Lifetime Value – CLV) là tổng giá trị lợi nhuận mà một khách hàng mang lại cho doanh nghiệp trong suốt vòng đời của họ. Churn prediction thường được kết hợp với CLV để ưu tiên giữ chân khách hàng giá trị cao và phân bổ ngân sách marketing hiệu quả. Việc dự báo churn mà không xem xét CLV có thể dẫn đến việc tối ưu sai mục tiêu (giữ chân khách hàng lợi nhuận thấp trong khi bỏ qua khách hàng giá trị cao).

2.1.4. Đặc điểm dữ liệu churn

Dữ liệu churn có ba đặc điểm chính: (1) Mất cân bằng lớp – tỷ lệ churn thường thấp hơn nhiều so với non-churn; (2) Tính phi tuyến – hành vi khách hàng chịu ảnh hưởng bởi nhiều yếu tố phức tạp; (3) Nhiều chiều – bao gồm hàng chục đến hàng trăm đặc trưng.

2.1.5. Học máy trong dự báo churn

Học máy là phương pháp cho phép mô hình học từ dữ liệu lịch sử để đưa ra dự đoán tương lai. Các nhóm thuật toán thường dùng bao gồm: hồi quy logistic, cây quyết định, Random Forest, Gradient Boosting (XGBoost, LightGBM, CatBoost) và học sâu (ANN, RNN).

2.1.6. Dữ liệu mất cân bằng

Nếu không xử lý mất cân bằng, mô hình sẽ thiên lệch về lớp đa số, Recall cho churn thấp và Accuracy cao nhưng không có giá trị thực tiễn. Các kỹ thuật xử lý bao gồm: Random

Oversampling, Random Undersampling, SMOTE (Synthetic Minority Over-sampling Technique) và các phương pháp ensemble nhạy với imbalance.

2.1.7. Học kết hợp

Học kết hợp (Ensemble Learning) là phương pháp kết hợp nhiều mô hình để cải thiện hiệu suất dự báo. Hai nhóm chính là: Bagging (Random Forest) và Boosting (AdaBoost, Gradient Boosting, XGBoost). Học kết hợp thường vượt trội so với mô hình đơn lẻ trên dữ liệu bảng.

2.1.8. Trí tuệ nhân tạo có thể giải thích

Trí tuệ nhân tạo có thể giải thích (XAI) nhằm giải quyết vấn đề "hộp đen" của mô hình phức tạp với mục tiêu: giải thích tại sao mô hình đưa ra dự đoán, tăng tính minh bạch và hỗ trợ ra quyết định. SHAP là một trong những phương pháp phổ biến nhất hiện nay, được sử dụng rộng rãi để phân tích tầm quan trọng đặc trưng và giải thích từng dự đoán cá nhân.

2.2. Tổng quan các nghiên cứu liên quan (2020–2025)

Trong giai đoạn 2020–2025, lĩnh vực churn prediction có các xu hướng nghiên cứu nổi bật: học kết hợp, kết hợp PCA và Boosting, học sâu với cơ chế Attention, và tích hợp trí tuệ nhân tạo có thể giải thích. Bảng 2.1 tổng hợp các bài báo tiêu biểu đại diện cho các hướng nghiên cứu đó.

Bảng 2.1: Tổng hợp các nghiên cứu liên quan về dự báo rời bỏ khách hàng (2020–2025)

STT	Tên bài báo	Tác giả	Mục tiêu	Phương pháp	Kết quả	Gợi ý tương lai
1	*Customer Churn Prediction Using Machine Learning Techniques in the E-Commerce Sector*	Lalwani et al. (2022)	Dự báo churn trong thương mại điện tử; so sánh hiệu suất nhiều thuật toán ML trên dữ liệu mất cân bằng.	Random Forest, XGBoost, hồi quy logistic; SMOTE để xử lý mất cân bằng; đánh giá Accuracy, F1, AUC-ROC.	XGBoost đạt AUC-ROC = 0,91; SMOTE cải thiện Recall từ 0,54 lên 0,81; Random Forest đứng thứ hai.	Tích hợp dữ liệu hành vi thời gian thực (clickstream); kết hợp CLV để ưu tiên giữ chân.
2	*Explainable Artificial Intelligence for Customer Churn Prediction in Retail Banking*	Bussmann et al. (2021)	Tích hợp XAI vào mô hình churn prediction để hỗ trợ ra quyết định minh bạch trong lĩnh vực ngân hàng.	XGBoost kết hợp SHAP values; phân tích tầm quan trọng toàn cục và giải thích cục bộ dạng Waterfall.	SHAP xác định Balance, Age, NumOfProducts là ba đặc trưng quan trọng nhất; mô hình đạt F1 = 0,85.	Mở rộng sang LIME và Counterfactual Explanation; áp dụng cho bảo hiểm và viễn thông.
3	*A Hybrid Model for Churn Prediction: Combining PCA Dimensionality Reduction with AdaBoost Classifier*	Zhang & Wang (2022)	Giảm chiều dữ liệu và cải thiện hiệu suất tổng quát hóa cho bài toán churn; giảm overfitting.	PCA để giảm chiều; AdaBoost là classifier chính; GridSearchCV tối ưu siêu tham số.	Kết hợp PCA-AdaBoost đạt Accuracy 92,3%; giảm 40% thời gian huấn luyện so với mô hình full-feature.	Thử nghiệm với LDA thay PCA; áp dụng Bayesian Optimization thay GridSearch.
4	*Deep Learning-Based Customer Churn Prediction with Attention Mechanism for Sequential Behavioral Data*	Ahmad et al. (2023)	Khai thác thông tin chuỗi thời gian trong hành vi khách hàng; cải thiện khả năng phát hiện tín hiệu sớm.	LSTM với cơ chế Attention; dữ liệu chuỗi 12 tháng; tối ưu bằng Adam với learning rate scheduling.	Attention-LSTM đạt AUC-ROC = 0,94, cao hơn XGBoost tĩnh 2,3%; đặc biệt hiệu quả với dữ liệu dài hạn.	Kết hợp mô hình dựa trên Transformer; tích hợp dữ liệu đa phương thức (văn bản phản hồi, hình ảnh).

(Tiếp theo Bảng 2.1)

STT	Tên bài báo	Tác giả	Mục tiêu	Phương pháp	Kết quả	Gợi ý tương lai
5	*Churn Prediction in Telecommunications Using XGBoost with Hyperparameter Optimization*	Reddy (2024)	Tối ưu hóa siêu tham số XGBoost cho dự báo churn viễn thông; đạt độ chính xác tối đa.	XGBoost + Bayesian Optimization (Optuna); cross-validation 5-fold; so sánh với Random Forest và LightGBM.	Accuracy 95,2%; AUC-ROC = 0,97; XGBoost vượt trội LightGBM trong điều kiện tập dữ liệu nhỏ–trung bình.	Triển khai hệ thống tái huấn luyện tự động; thêm SHAP để giải thích kết quả cho đội ngũ kinh doanh.
6	*Addressing Class Imbalance in E-Commerce Churn Prediction: A Comparative Study of Resampling Techniques*	Vo et al. (2023)	So sánh toàn diện các kỹ thuật xử lý mất cân bằng; tìm phương pháp tốt nhất cho churn e-commerce.	So sánh SMOTE, ADASYN, Random Oversampling, Class Weighting; mô hình nền là Random Forest và XGBoost.	SMOTE kết hợp XGBoost đạt Recall tốt nhất (0,86); ADASYN cho F1 cao hơn nhưng dễ overfit hơn.	Nghiên cứu ảnh hưởng tỷ lệ oversampling tối ưu; kết hợp cost-sensitive learning với resampling.
7	*Real-Time Customer Churn Prediction: A Streaming Machine Learning Approach*	Kaur & Singh (2024)	Xây dựng hệ thống dự báo churn thời gian thực trên dữ liệu luồng (streaming data).	Apache Kafka + Flink; River (online ML); mô hình cập nhật liên tục (incremental learning).	Độ trễ dự báo dưới 300ms; AUC-ROC = 0,89 trên dữ liệu thực từ sàn thương mại điện tử Ấn Độ.	Tích hợp XAI vào pipeline streaming; nghiên cứu concept drift detection tự động.
8	*Customer Churn Prediction with Causal Inference: Beyond Correlation to Causation*	Li & Chen (2024)	Xác định các yếu tố có quan hệ nhân quả thực sự với hành vi churn, thay vì chỉ tương quan thống kê.	Causal Forest (CausalML); Propensity Score Matching; so sánh với XGBoost thuần tương quan.	Mô hình nhân quả xác định 4 biến nhân quả thực sự; loại bỏ 3 biến tương quan giả; cải thiện ROI can thiệp 18%.	Kết hợp suy luận nhân quả với học tăng cường để tối ưu chiến lược giữ chân; áp dụng A/B testing.

2.2.1. Nhận xét tổng hợp và câu hỏi nghiên cứu chung

Từ việc phân tích 8 công trình tiêu biểu trong bảng tổng hợp, có thể rút ra một số nhận xét chính như sau:

Về phương pháp: XGBoost và các biến thể Gradient Boosting tiếp tục thể hiện ưu thế vượt trội trên dữ liệu bảng (tabular), đạt AUC-ROC từ 0,91 đến 0,97 trong nhiều nghiên cứu độc lập (Lalwani et al., 2022; Reddy, 2024; Vo et al., 2023). Học sâu với cơ chế Attention (Ahmad et al., 2023) cho thấy tiềm năng lớn khi khai thác dữ liệu chuỗi thời gian, song đòi hỏi tài nguyên tính toán cao và khó triển khai thực tế hơn.

Về xử lý mất cân bằng: SMOTE vẫn là kỹ thuật phổ biến và hiệu quả nhất (Vo et al., 2023; Lalwani et al., 2022), đặc biệt khi kết hợp với các mô hình ensemble. Tuy nhiên, việc áp dụng đúng kỹ thuật (chỉ trên tập train) vẫn là vấn đề nhiều nghiên cứu chưa xử lý triệt để, dẫn đến nguy cơ data leakage.

Về tính minh bạch: Xu hướng tích hợp trí tuệ nhân tạo có thể giải thích – đặc biệt là SHAP – ngày càng trở thành yêu cầu bắt buộc trong các ứng dụng kinh doanh thực tế (Bussmann et al., 2021). Tuy nhiên, hầu hết nghiên cứu mới dừng ở mức phân tích ngoại tuyến, chưa tích hợp SHAP vào giao diện người dùng tương tác.

Về khoảng trống nghiên cứu: Các nghiên cứu chưa đồng thời giải quyết ba bài toán: (i) độ chính xác cao với dữ liệu mất cân bằng, (ii) khả năng giải thích minh bạch tích hợp vào hệ thống, và (iii) triển khai thực tiễn dưới dạng ứng dụng hỗ trợ ra quyết định cho người dùng cuối.

Từ những phân tích trên, câu hỏi nghiên cứu chung được đặt ra như sau:

> *"Làm thế nào để xây dựng một hệ thống dự báo churn có độ chính xác cao, xử lý hiệu quả dữ liệu mất cân bằng và đồng thời cung cấp khả năng giải thích minh bạch tích hợp cho từng dự đoán cá nhân, có thể triển khai dưới dạng ứng dụng thực tế hỗ trợ ra quyết định trong môi trường thương mại điện tử?"*

Câu hỏi này phản ánh sự giao thoa giữa ba hướng nghiên cứu: học kết hợp (đại diện bởi XGBoost), kỹ thuật tái cân bằng dữ liệu (SMOTE), và trí tuệ nhân tạo có thể giải

thích (SHAP), đồng thời định hướng nghiên cứu hướng đến tính ứng dụng thực tiễn – điều mà các công trình trước còn bỏ ngỏ.

2.3. Lý thuyết và mô hình được áp dụng

2.3.1. Lý thuyết Gradient Boosting

Gradient Boosting là phương pháp xây dựng mô hình theo từng bước, mỗi bước giảm sai số của mô hình trước. XGBoost cải tiến bằng: điều chuẩn hóa, tính toán song song và pruning cây.

2.3.2. XGBoost

XGBoost (Extreme Gradient Boosting) là thuật toán boosting tối ưu hóa tốc độ và hiệu suất với ưu điểm: xử lý tốt dữ liệu phi tuyến, giảm overfitting và tính toán nhanh. Hàm mục tiêu:

$$\mathscr{L}(\theta) = \sum_i \ell(\hat{y}_i, y_i) + \sum_k \Omega(f_k) \tag{2.1}$$

trong đó ℓ đo sai số dự đoán và Ω kiểm soát độ phức tạp mô hình.

2.3.3. SMOTE

SMOTE tạo mẫu tổng hợp cho lớp thiểu số bằng cách chọn điểm dữ liệu thiểu số, chọn k hàng xóm gần nhất và nội suy để tạo điểm mới, giúp cải thiện Recall và giảm thiên lệch mô hình.

2.3.4. SHAP (Shapley Additive Explanations)

SHAP dựa trên giá trị Shapley trong lý thuyết trò chơi hợp tác. Mỗi đặc trưng được xem là một "người chơi" và giá trị Shapley đo đóng góp biên của từng đặc trưng vào dự đoán cuối cùng. SHAP cung cấp: biểu đồ tầm quan trọng toàn cục, giải thích cục bộ, Waterfall Plot và Summary Plot.

2.3.5. Các chỉ số đánh giá

Trong dữ liệu mất cân bằng, Recall và ROC-AUC quan trọng hơn Accuracy: Accuracy phản ánh tỷ lệ dự đoán đúng tổng thể; Recall phản ánh khả năng phát hiện đúng churn trên tổng churn thực tế; F1-score là trung bình điều hòa của Precision và Recall; ROC-AUC đo khả năng phân biệt hai lớp.

3. Phương pháp thực hiện

3.1. Tổng quan phương pháp nghiên cứu

Nghiên cứu này áp dụng quy trình khoa học dữ liệu theo chuẩn CRISP-DM kết hợp với các kỹ thuật học máy hiện đại nhằm xây dựng một hệ thống dự đoán hành vi rời bỏ của khách hàng thương mại điện tử. Quy trình được thiết kế theo hướng end-to-end, bắt đầu từ giai đoạn thu thập và làm sạch dữ liệu thô, trải qua các bước tiền xử lý, khám phá phân tích, xây dựng và đánh giá mô hình, và kết thúc bằng việc triển khai hệ thống thực tiễn dưới dạng ứng dụng web tương tác.

Điểm đặc biệt của phương pháp nghiên cứu trong đề tài này là sự tích hợp chặt chẽ giữa khả năng dự đoán và khả năng giải thích. Trong nhiều bài toán kinh doanh thực tế, đặc biệt là trong lĩnh vực quản trị quan hệ khách hàng, việc chỉ có một con số xác suất dự đoán là chưa đủ. Người ra quyết định – bao gồm các nhà quản lý kinh doanh, chuyên viên chăm sóc khách hàng – cần hiểu được tại sao hệ thống đưa ra kết luận đó để có thể hành động một cách có chủ đích và phù hợp với từng cá nhân khách hàng. Do đó, kỹ thuật SHAP được lựa chọn như một thành phần cốt lõi không thể tách rời khỏi kiến trúc hệ thống.

Về mặt công cụ kỹ thuật, toàn bộ hệ thống phân tích được xây dựng trên ngôn ngữ lập trình Python 3.12, tận dụng hệ sinh thái thư viện mã nguồn mở. Môi trường thực thi được quản lý thông qua Anaconda, đảm bảo tính tái lập của kết quả. Cụ thể, các thư viện chính được sử dụng bao gồm:

- Pandas (3.0.1) và NumPy (1.24): Xử lý và biến đổi dữ liệu dạng bảng, thực hiện các phép tính ma trận và vector hóa dữ liệu với hiệu năng cao.

- Scikit-learn (1.3): Cung cấp các công cụ tiền xử lý dữ liệu chuẩn hóa (StandardScaler, LabelEncoder, OneHotEncoder), phân tách tập dữ liệu (train_test_split), và các thang đo đánh giá mô hình (classification_report, confusion_matrix, roc_auc_score).
- Imbalanced-learn (0.11): Cung cấp thuật toán SMOTE chuyên dụng để giải quyết vấn đề mất cân bằng nhãn trong tập huấn luyện.
- XGBoost (1.7): Thư viện cốt lõi cho việc xây dựng và huấn luyện mô hình phân loại Gradient Boosted Trees với tối ưu hóa song song trên CPU.
- SHAP (0.42): Thư viện tính toán giá trị Shapley để phân rã đóng góp của từng đặc trưng vào dự đoán cuối cùng, cung cấp khả năng giải thích ở cả cấp độ toàn cục và cục bộ.
- Matplotlib và Seaborn: Trực quan hóa dữ liệu trong giai đoạn khám phá và đánh giá mô hình.
- Streamlit (1.28): Framework Python để triển khai giao diện web tương tác mà không cần viết mã HTML/CSS/JavaScript trực tiếp, phù hợp với quy mô nguyên mẫu (prototype) và ứng dụng phân tích nội bộ.
- Joblib: Lưu trữ và tải lại mô hình XGBoost đã huấn luyện cùng với đối tượng StandardScaler dưới dạng tệp nhị phân `.pkl` để tái sử dụng trong môi trường triển khai.

3.2. Dữ liệu và tiêu chí lựa chọn

3.2.1. Mô tả tập dữ liệu

Tập dữ liệu được sử dụng trong nghiên cứu này là bộ dữ liệu "Churn Modelling" – một benchmark dataset phổ biến trong cộng đồng học máy ứng dụng cho bài toán dự đoán hành vi khách hàng trong lĩnh vực tài chính và thương mại điện tử. Bộ dữ liệu bao gồm 10.000 bản ghi quan sát với 14 thuộc tính đầu vào, phản ánh hồ sơ nhân khẩu học và lịch sử giao dịch của khách hàng trong một giai đoạn nhất định.

Biến mục tiêu là `Exited` – nhận giá trị nhị phân $\{0, 1\}$ trong đó 1 đại diện cho khách hàng đã rời bỏ (churn) và 0 là khách hàng còn ở lại (retained). Trong tổng số 10.000 quan sát, có 2.037 khách hàng thuộc nhóm rời bỏ, tương đương tỷ lệ 20,37%.

Bảng 3.1 mô tả chi tiết các thuộc tính của tập dữ liệu:

Bảng 3.1: Mô tả chi tiết các thuộc tính trong tập dữ liệu Churn Modelling

Tên thuộc tính	**Kiểu dữ liệu**	**Mô tả**
RowNumber	Số nguyên	Số thứ tự hàng (loại bỏ trước huấn luyện)
CustomerId	Số nguyên	Mã định danh khách hàng (loại bỏ)
Surname	Chuỗi ký tự	Họ tên khách hàng (loại bỏ)
CreditScore	Số nguyên	Điểm tín dụng của khách hàng
Geography	Phân loại	Quốc gia cư trú (Pháp, Đức, Tây Ban Nha)
Gender	Phân loại	Giới tính (Male / Female)
Age	Số nguyên	Độ tuổi khách hàng
Tenure	Số nguyên	Số năm là khách hàng của nền tảng
Balance	Số thực	Số dư tài khoản (đơn vị tiền tệ)
NumOfProducts	Số nguyên	Số lượng sản phẩm/dịch vụ đang sử dụng
HasCrCard	Nhị phân	Có sở hữu thẻ tín dụng hay không
IsActiveMember	Nhị phân	Có phải thành viên đang hoạt động hay không
EstimatedSalary	Số thực	Mức lương ước tính
Exited	Nhị phân	**Biến mục tiêu**: 1 = Rời bỏ, 0 = Ở lại

3.2.2. Mẫu dữ liệu thực tế

Bảng 3.2 trình bày 5 dòng đầu của tập dữ liệu sau khi đã loại bỏ các cột nhận dạng, minh họa cấu trúc và phạm vi giá trị thực tế:

Bảng 3.2: Mẫu dữ liệu từ tập Churn_Modelling.csv (5 bản ghi đầu tiên)

Credit Score	Geography	Gender	Age	Tenure	Balance	Num Prod-ucts	Has Cr-Card	IsActive Member	Exited
619	France	Female	42	2	0.00	1	1	1	1
608	Spain	Female	41	1	83807.86	1	0	1	0
502	France	Female	42	8	159660.80	3	1	0	1
699	France	Female	39	1	0.00	2	0	0	0
850	Spain	Female	43	2	125510.82	1	1	1	0

3.2.3. Lý do lựa chọn tập dữ liệu

Bộ dữ liệu này được lựa chọn vì một số lý do kỹ thuật và thực tiễn. Thứ nhất, với quy mô 10.000 mẫu và 14 thuộc tính, đây là quy mô phù hợp để thực hiện toàn bộ quy trình học máy một cách rõ ràng và có kiểm soát, không quá lớn để gây khó khăn trong huấn luyện và không quá nhỏ để mô hình bị underfitting. Thứ hai, tỷ lệ mất cân bằng nhãn $\approx 4:1$ phản ánh đúng thực tế kinh doanh, tạo ra thách thức kỹ thuật thực sự đòi hỏi các kỹ thuật chuyên biệt như SMOTE. Thứ ba, sự kết hợp giữa các biến số (numerical), biến phân loại (categorical) và biến nhị phân (binary) tạo ra môi trường thực nghiệm đa dạng, phù hợp để minh họa đầy đủ quy trình tiền xử lý dữ liệu toàn diện.

3.3. Quy trình triển khai hệ thống

Luồng xử lý dữ liệu được thiết kế theo kiến trúc tuyến tính tuần tự với các bước được tổ chức rõ ràng, đảm bảo tính tái lập và khả năng mở rộng. Hình 3.1 minh họa toàn bộ quy trình từ đầu vào đến đầu ra.

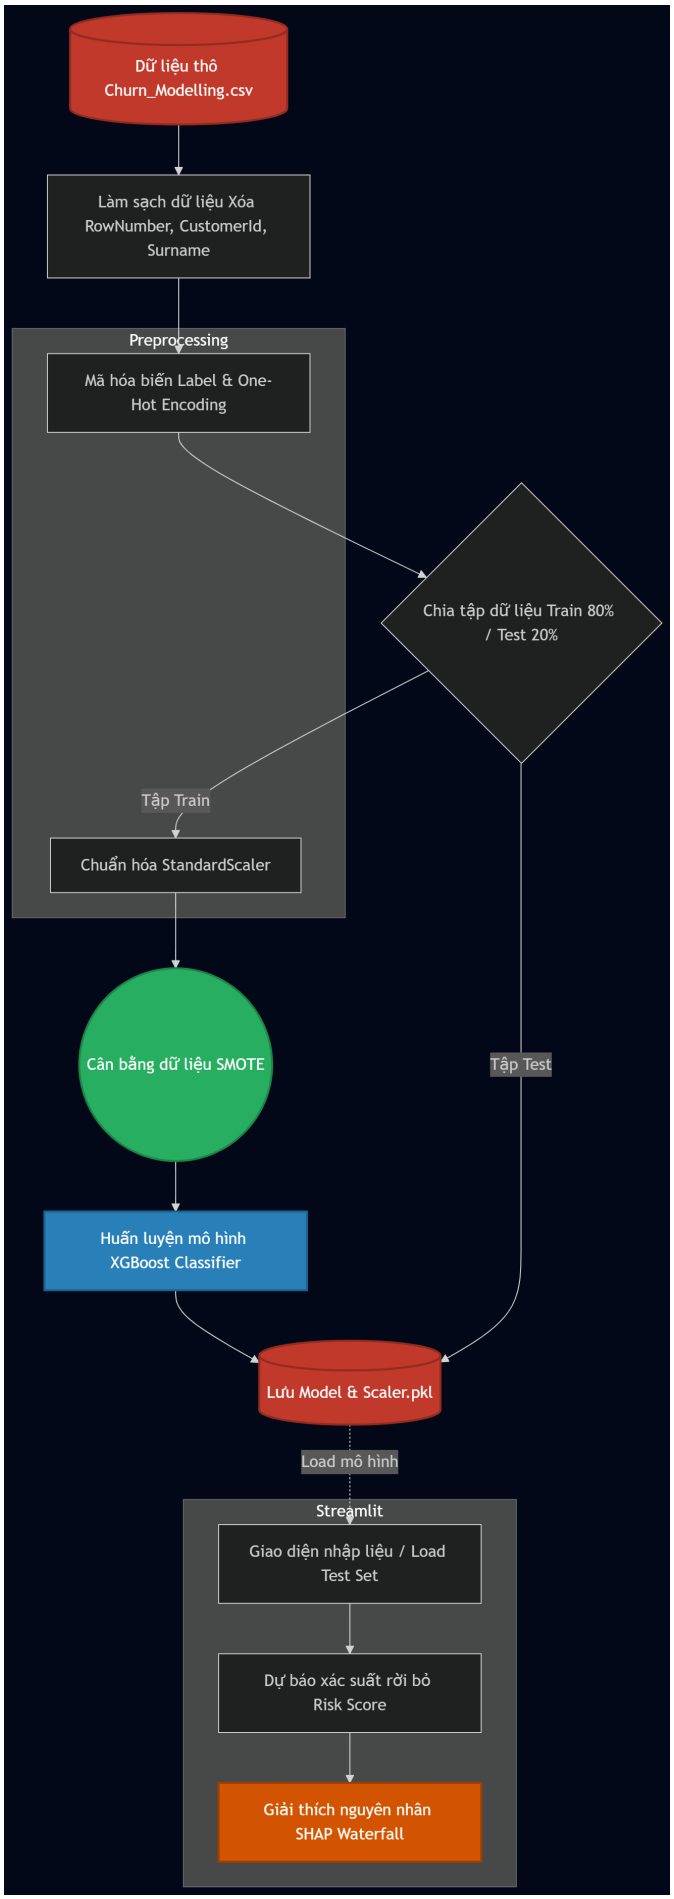

Hình 3.1: Sơ đồ luồng dữ liệu của hệ thống dự đoán churn

Hệ thống được triển khai thông qua bốn tệp mã nguồn Python độc lập, mỗi tệp đảm nhiệm một giai đoạn cụ thể trong pipeline. Cách tổ chức theo module này giúp dễ dàng bảo trì, kiểm thử và mở rộng từng thành phần riêng lẻ.

Giai đoạn 1 – Thu thập và làm sạch dữ liệu (`1_convert_to_json.py`): Tệp `Churn_Modelling.` được nạp vào bộ nhớ thông qua hàm `pandas.read_csv()`. Ba cột không mang thông tin dự đoán là `RowNumber`, `CustomerId`, và `Surname` bị loại bỏ. Dữ liệu sau làm sạch được lưu ra tệp CSV mới `Churn_Modelling_Cleaned.csv` và tệp JSON `Churn_Modelling.json` để phục vụ các bước tiếp theo và khả năng tích hợp API.

1_convert_to_json.py

```python
import pandas as pd
import os

current_dir = os.path.dirname(os.path.abspath(__file__))

raw_dir = os.path.join(current_dir, '..', 'Du_Lieu', 'Tho')
processed_dir = os.path.join(current_dir, '..', 'Du_Lieu', 'Da_Xu_Ly')

os.makedirs(processed_dir, exist_ok=True)

data_path = os.path.join(raw_dir, 'Churn_Modelling.csv')
print(f"Đang đọc dữ liệu từ: {data_path}")
df = pd.read_csv(data_path)

df_cleaned = df.drop(columns=['RowNumber', 'CustomerId', 'Surname'])

csv_path = os.path.join(processed_dir, 'Churn_Modelling_Cleaned.csv')
df_cleaned.to_csv(csv_path, index=False)
print(f"Đã lưu file CSV sạch tại: {csv_path}")

json_path = os.path.join(processed_dir, 'Churn_Modelling.json')
df_cleaned.to_json(json_path, orient='records', force_ascii=False, indent=4)
print(f"Đã lưu file JSON tại: {json_path}")
```

Hình 3.2: Mã nguồn tệp `1_convert_to_json.py` – Giai đoạn thu thập và làm sạch dữ liệu

Giai đoạn 2 – Khám phá và tiền xử lý dữ liệu (`2_eda_va_tien_xu_ly.py`): Giai đoạn này kết hợp hai nhiệm vụ: vẽ các biểu đồ EDA (phân phối độ tuổi, tỷ lệ rời bỏ theo giới tính) và thực hiện mã hóa biến phân loại. Biến `Gender` được ánh xạ sang $\{0, 1\}$ bằng Label Encoding; biến `Geography` được xử lý bằng One-Hot Encoding với tham số `drop_first=True` để tránh bẫy đa cộng tuyến. Kết quả được lưu ra `Churn_Encoded.csv`.

```python
2_eda_va_tien_xu_ly.py

import pandas as pd
import os
import matplotlib.pyplot as plt
import seaborn as sns

current_dir = os.path.dirname(os.path.abspath(__file__))
processed_dir = os.path.join(current_dir, '..', 'Du_Lieu', 'Da_Xu_Ly')
img_dir = os.path.join(current_dir, '..', '..', '2_Bao_Cao_Hoc_Thuat', 'Hinh_Anh_Bao_Cao')
os.makedirs(img_dir, exist_ok=True)

data_path = os.path.join(processed_dir, 'Churn_Modelling_Cleaned.csv')
df = pd.read_csv(data_path)


print("Đang vẽ biểủ đồ`EDA...")
sns.set_theme(style="whitegrid")

plt.figure(figsize=(8, 5))
sns.countplot(data=df, x='Gender', hue='Exited', palette='Set2')
plt.title('Tỷ lệ rời bỏ khách hàng theo Giới tính')
plt.savefig(os.path.join(img_dir, 'EDA_Churn_by_Gender.png'), dpi=300)
plt.close()

plt.figure(figsize=(8, 5))
sns.histplot(data=df, x='Age', hue='Exited', multiple="stack", kde=True, palette='viridis')
plt.title('Phân phôí Độ tuổỉ theo trạng thái Rời bỏ')
plt.savefig(os.path.join(img_dir, 'EDA_Age_Distribution.png'), dpi=300)
plt.close()

print("Đang mã hóa dữ liệu...")
df['Gender'] = df['Gender'].map({'Female': 0, 'Male': 1})

df = pd.get_dummies(df, columns=['Geography'], drop_first=True)

encoded_path = os.path.join(processed_dir, 'Churn_Encoded.csv')
df.to_csv(encoded_path, index=False)
print(f"Đã lưu dữ liệu mã hóa tại: {encoded_path}")
print(f"Đã lưu hình ảnh biểủ đồ`tại: {img_dir}")
```

Hình 3.3: Mã nguồn tệp `2_eda_va_tien_xu_ly.py` – Giai đoạn EDA và tiền xử lý dữ liệu

Giai đoạn 3 – Huấn luyện mô hình (`3_train_model.py`): Đây là giai đoạn cốt lõi của pipeline. Tập dữ liệu sau mã hóa được phân tách theo tỷ lệ 80/20, chuẩn hóa bằng StandardScaler (chỉ fit trên tập train), sau đó áp dụng SMOTE để cân bằng nhãn. Mô hình XGBoost được huấn luyện trên tập sau SMOTE và đánh giá trên tập test gốc. Mô hình và scaler được lưu dưới dạng tệp `.pkl`.

3_train_model.py

```python
import pandas as pd
import os
import joblib
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from xgboost import XGBClassifier
from sklearn.metrics import classification_report, accuracy_score, recall_score
from imblearn.over_sampling import SMOTE

current_dir = os.path.dirname(os.path.abspath(__file__))
processed_dir = os.path.join(current_dir, '..', 'Du_Lieu', 'Da_Xu_Ly')
model_dir = os.path.join(current_dir, '..', 'Da_Xu_Ly') # Lưu model ở đây cho tiện

df = pd.read_csv(os.path.join(processed_dir, 'Churn_Encoded.csv'))

X = df.drop('Exited', axis=1)
y = df['Exited']

X_train, X_test, y_train, y_test = train_test_split(X, y, test_size=0.2, random_state=42, stratify=y)

scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled = scaler.transform(X_test)

print("Đang áp dụng SMOTE để cân bằng dữ liệu...")
smote = SMOTE(random_state=42)
X_train_resampled, y_train_resampled = smote.fit_resample(X_train_scaled, y_train)

print("Đang huấn luyện mô hình XGBoost...")
model = XGBClassifier(n_estimators=100, learning_rate=0.1, max_depth=5, random_state=42)
model.fit(X_train_resampled, y_train_resampled)

y_pred = model.predict(X_test_scaled)
print("\n=== KẾT QUẢ ĐÁNH GIÁ MÔ HÌNH ===")
print(f"Độ chính xác (Accuracy): {accuracy_score(y_test, y_pred):.4f}")
print(f"Độ nhạy (Recall): {recall_score(y_test, y_pred):.4f}")
print("\nBáo cáo chi tiết:")
print(classification_report(y_test, y_pred))

joblib.dump(model, os.path.join(processed_dir, 'xgboost_model.pkl'))
joblib.dump(scaler, os.path.join(processed_dir, 'scaler.pkl'))
X_test.to_csv(os.path.join(processed_dir, 'X_test_raw.csv'), index=False) # Lưu X_test nguyên bản để vẽ SHAP cho đẹp
print(f"\nĐã lưu Model và Scaler thành công!")
```

Hình 3.4: Mã nguồn tệp `3_train_model.py` – Giai đoạn huấn luyện mô hình XGBoost

Giai đoạn 4 – Phân tích SHAP (`4_xai_shap.py`): Tệp này tải mô hình và scaler đã lưu, tính toán SHAP values trên tập test thông qua `shap.Explainer`, và xuất biểu đồ SHAP Summary Plot dưới dạng hình ảnh PNG.

```python
import pandas as pd
import os
import joblib
import shap
import matplotlib.pyplot as plt

current_dir = os.path.dirname(os.path.abspath(__file__))
processed_dir = os.path.join(current_dir, '..', 'Du_Lieu', 'Da_Xu_Ly')
img_dir = os.path.join(current_dir, '..', '..', '2_Bao_Cao_Hoc_Thuat', 'Hinh_Anh_Bao_Cao')

print("Đang tải mô hình và dữ liệu...")
model = joblib.load(os.path.join(processed_dir, 'xgboost_model.pkl'))
scaler = joblib.load(os.path.join(processed_dir, 'scaler.pkl'))
X_test_raw = pd.read_csv(os.path.join(processed_dir, 'X_test_raw.csv'))

X_test_scaled = scaler.transform(X_test_raw)

print("Đang tính toán giá trị SHAP (Có thể mất vài giây)...")
explainer = shap.Explainer(model)
shap_values = explainer(X_test_scaled)

plt.figure(figsize=(10, 6))
shap.summary_plot(shap_values, X_test_raw, show=False) # Dùng X_test_raw để hiện đúng tên cột và giá trị thực tế
plt.title("Phân tích tầm quan trọng của các đặc trưng (SHAP Values)", fontsize=14, pad=20)
plt.tight_layout()

shap_img_path = os.path.join(img_dir, 'XAI_SHAP_Summary.png')
plt.savefig(shap_img_path, dpi=300, bbox_inches='tight')
plt.close()

print(f"Đã lưu biểu đồ SHAP tại: {shap_img_path}")
```

Hình 3.5: Mã nguồn tệp `4_xai_shap.py` – Giai đoạn phân tích XAI với SHAP

Giai đoạn 5 – Giao diện web (`app.py`): Tệp Streamlit cuối cùng tích hợp toàn bộ các thành phần: tải mô hình, chuẩn hóa dữ liệu đầu vào, dự đoán xác suất rời bỏ, hiển thị danh sách khách hàng phân loại theo mức độ rủi ro, và cung cấp phân tích SHAP Waterfall tương tác cho từng cá nhân.

app.py

```python
import streamlit as st
import pandas as pd
import joblib
import shap
import matplotlib.pyplot as plt
import os

st.set_page_config(page_title="E-Commerce Churn Dashboard", page_icon="", layout="wide")
st.title("  Hệ thống Dự báo Rời bỏ Khách hàng (Customer Churn)")
st.markdown("---")


@st.cache_resource
def load_assets():
    current_dir = os.path.dirname(os.path.abspath(__file__))
    processed_dir = os.path.join(current_dir, '..', 'Du_Lieu', 'Da_Xu_Ly')

    model = joblib.load(os.path.join(processed_dir, 'xgboost_model.pkl'))
    scaler = joblib.load(os.path.join(processed_dir, 'scaler.pkl'))

    df_new = pd.read_csv(os.path.join(processed_dir, 'X_test_raw.csv'))
    return model, scaler, df_new


try:
    model, scaler, df_new = load_assets()
except Exception as e:
    st.error(f"Lỗi tải dữ liệu. Hãy chắc chắn bạn đã chạy 3 file code trước đó! Chi tiết: {e}")
    st.stop()

X_scaled = scaler.transform(df_new)

churn_probs = model.predict_proba(X_scaled)[:, 1]

df_display = df_new.copy()
df_display['Risk_Score (%)'] = (churn_probs * 100).round(2)
df_display['Dự đoán'] = df_display['Risk_Score (%)'].apply(lambda x: 'Nguy cơ cao' if x > 50 else 'An toàn')

st.subheader("1. Tổng quan tình trạng Khách hàng")
col1, col2, col3 = st.columns(3)
with col1:
    st.metric("Tổng số khách hàng quét", len(df_display))
with col2:
    high_risk_count = len(df_display[df_display['Risk_Score (%)'] > 50])
    st.metric("Số khách hàng Nguy cơ cao", high_risk_count, delta_color="inverse")
with col3:
    avg_risk = df_display['Risk_Score (%)'].mean()
    st.metric("Tỷ lệ rủi ro trung bình", f"{avg_risk:.1f}%")

st.markdown("---")

st.subheader("2. Danh sách Khách hàng & Điểm rủi ro")
st.write("Bộ phận CSKH sử dụng bảng này để ưu tiên gọi điện/tặng voucher cho khách có màu Đỏ/Cam.")

df_display_sorted = df_display.sort_values(by='Risk_Score (%)', ascending=False)


def color_risk(val):
    color = 'red' if val > 70 else 'orange' if val > 40 else 'green'
    return f'color: {color}; font-weight: bold'


st.dataframe(
    df_display_sorted.style.map(color_risk, subset=['Risk_Score (%)']),
    use_container_width=True,
    height=300
)
st.markdown("---")

st.subheader("3. Phân tích nguyên nhân rời bỏ (AI Explainability)")
st.write("Chọn một khách hàng cụ thể để xem tại sao hệ thống AI lại dự đoán người này sắp bỏ đi.")

selected_idx = st.selectbox("Chọn Mã Khách Hàng (Index):", df_display_sorted.index.tolist())

# Nút bấm để phân tích
if st.button("  Phân tích nguyên nhân"):
    with st.spinner("Hệ thống đang trích xuất đồ thị SHAP..."):
        customer_data = X_scaled[selected_idx].reshape(1, -1)

        explainer = shap.Explainer(model)
        shap_values_single = explainer(customer_data)

        shap_values_single.feature_names = df_new.columns.tolist()

        fig, ax = plt.subplots(figsize=(8, 4))
        shap.plots.waterfall(shap_values_single[0], show=False)
        plt.tight_layout()

        st.pyplot(fig)

        st.info(
            "  **Hướng dẫn đọc biểu đồ:** Thanh màu Đỏ đẩy điểm rủi ro tăng lên (Lý do khách rời bỏ). Thanh màu Xanh kéo điểm rủi ro xuống (Lý do khách muốn ở lại).")
```

Hình 3.6: Mã nguồn tệp `app.py` – Giao diện web Streamlit Dashboard

3.4. Tiền xử lý và khắc phục mất cân bằng dữ liệu

3.4.1. Chuẩn hóa đặc trưng bằng StandardScaler

Mặc dù XGBoost thuộc họ thuật toán dựa trên cây quyết định – vốn có tính bất biến đối với phép đổi tỷ lệ đơn điệu của đặc trưng – nhưng trong hệ thống này, bước chuẩn hóa vẫn được duy trì vì hai lý do thực tiễn quan trọng.

Lý do thứ nhất liên quan đến tính nhất quán của pipeline triển khai: Khi ứng dụng Streamlit nhận dữ liệu mới từ người dùng, dữ liệu đó cần được xử lý qua đúng cùng bước

biến đổi như dữ liệu đã được dùng trong huấn luyện. Lý do thứ hai là để tương thích với các mô hình khác trong trường hợp mở rộng hệ thống về sau (ví dụ: hồi quy logistic, SVM, MLP).

Bước chuẩn hóa chỉ được fit (`fit_transform`) trên tập train, sau đó chỉ được áp dụng (`transform`) lên tập test – một nguyên tắc cơ bản để tránh data leakage từ tập test vào quá trình huấn luyện.

3.4.2. Kỹ thuật SMOTE – giải quyết mất cân bằng nhãn

Bài toán phân loại với nhãn mất cân bằng là một trong những thách thức kỹ thuật phổ biến nhất trong học máy ứng dụng cho lĩnh vực kinh doanh. Khi tỷ lệ nhãn dương (khách hàng rời bỏ) chỉ chiếm 20,37%, các thuật toán học máy cơ bản có xu hướng thiên vị về phía nhãn đa số.

SMOTE (Synthetic Minority Over-sampling Technique) giải quyết vấn đề này bằng cách tổng hợp các mẫu mới thông qua nội suy tuyến tính trong không gian đặc trưng. Thuật toán SMOTE hoạt động như sau:

1. Với mỗi mẫu x_i thuộc nhóm thiểu số, tìm k láng giềng gần nhất trong cùng nhóm thiểu số (mặc định $k = 5$).
2. Chọn ngẫu nhiên một láng giềng x_{nn} trong số k láng giềng đó.
3. Tổng hợp mẫu mới x_{new} theo công thức nội suy:

$$x_{new} = x_i + \lambda \cdot (x_{nn} - x_i), \quad \lambda \in [0,1] \text{ (ngẫu nhiên đều)} \tag{3.1}$$

4. Lặp lại quá trình cho đến khi số mẫu trong nhóm thiểu số bằng với nhóm đa số.

Một điểm kỹ thuật quan trọng cần lưu ý: SMOTE được áp dụng sau bước phân tách train/test và chỉ trên tập train, tránh hiện tượng rò rỉ dữ liệu.

3.5. Đặc tả thuật toán XGBoost

3.5.1. Nền tảng lý thuyết: Gradient Boosting

XGBoost (Extreme Gradient Boosting) là một triển khai tối ưu hóa hiệu năng cao của thuật toán Gradient Boosted Decision Trees (GBDT), được phát triển bởi Chen & Guestrin (2016). Gradient Boosting thuộc lớp thuật toán học kết hợp theo phương pháp Boosting, xây dựng một mô hình mạnh bằng cách kết hợp tuần tự nhiều mô hình yếu. Mỗi cây mới được xây dựng để sửa chữa các lỗi của cây trước bằng cách học trên phần dư.

Hình 3.7 minh họa lưu đồ thuật toán huấn luyện XGBoost trong bài toán phân loại nhị phân:

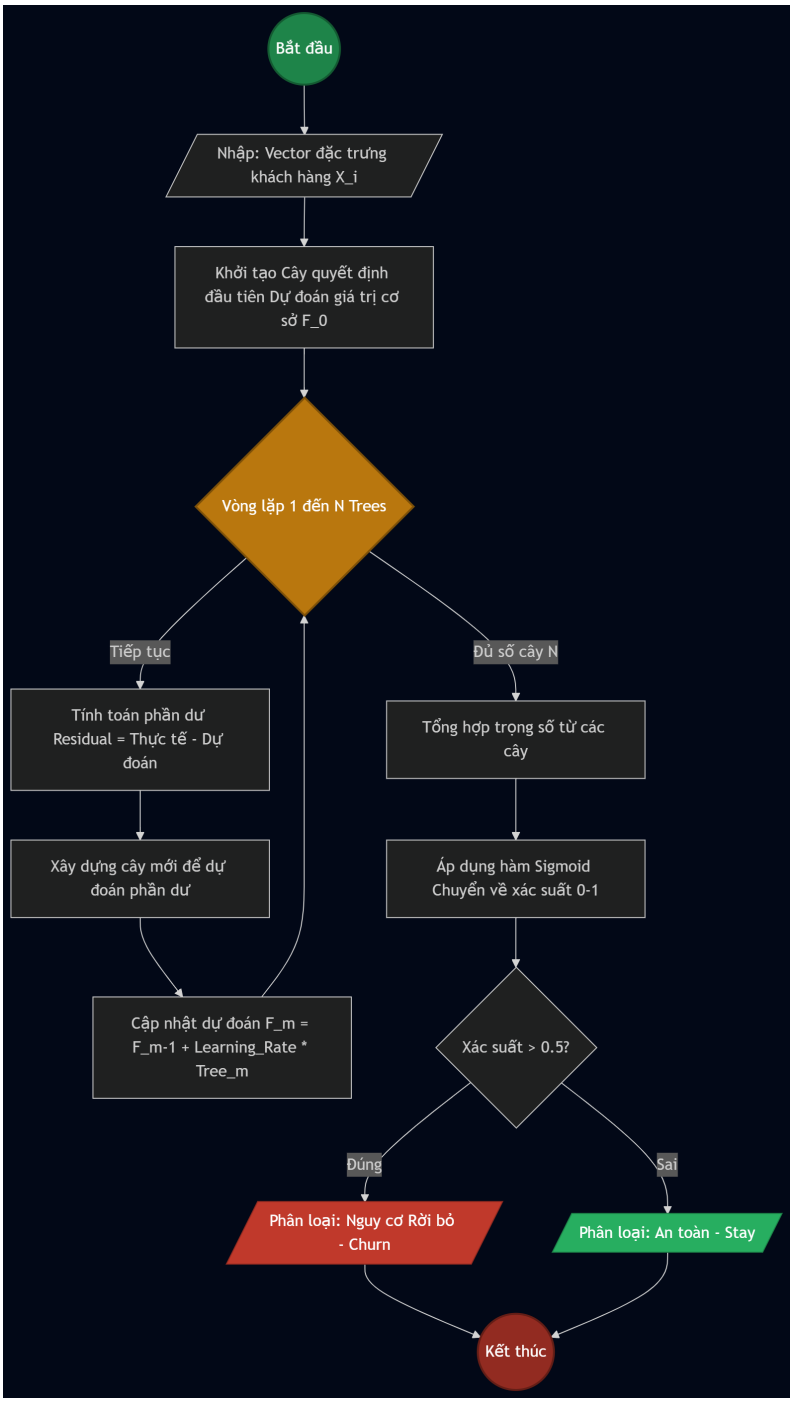

Hình 3.7: Lưu đồ thuật toán huấn luyện mô hình XGBoost

Hàm mục tiêu của XGBoost:

$$\mathscr{L}(\phi) = \sum_i l(\hat{y}_i, y_i) + \sum_k \Omega(f_k) \tag{3.2}$$

trong đó $\Omega(f)$ là thành phần điều chuẩn:

$$\Omega(f) = \gamma T + \frac{1}{2}\lambda \|w\|^2 \tag{3.3}$$

Thành phần Ω chính là điểm phân biệt của XGBoost so với GBDT truyền thống, tích hợp kiểm soát độ phức tạp mô hình ngay trong hàm mục tiêu.

3.5.2. Cơ chế tối ưu hóa hàm mất mát

Tại vòng lặp Boosting thứ m, XGBoost sử dụng xấp xỉ Taylor bậc hai:

$$\mathscr{L}^{(m)} \approx \sum_{i=1}^{n} \left[l(y_i, \hat{y}_i^{(m-1)}) + g_i f_m(x_i) + \frac{1}{2} h_i f_m^2(x_i) \right] + \Omega(f_m) \tag{3.4}$$

trong đó g_i là đạo hàm bậc nhất (gradient) và h_i là đạo hàm bậc hai (Hessian) của hàm mất mát. Sử dụng thông tin Hessian giúp XGBoost hội tụ nhanh hơn và ổn định hơn.

3.5.3. Siêu tham số và chiến lược cấu hình

Bảng 3.3 trình bày bộ siêu tham số được lựa chọn dựa trên thực nghiệm:

Bảng 3.3: Bộ siêu tham số của mô hình XGBoost được sử dụng trong nghiên cứu

Siêu tham số	**Giá trị**	**Ý nghĩa**
`n_estimators`	100	Số lượng cây trong tổ hợp
`max_depth`	5	Độ sâu tối đa của mỗi cây quyết định
`learning_rate`	0.1	Tốc độ học (thu nhỏ đóng góp của mỗi cây)
`random_state`	42	Seed ngẫu nhiên để đảm bảo tái lập

3.6. Chỉ số đánh giá hiệu suất mô hình

3.6.1. Tại sao Accuracy không phải là chỉ số phù hợp

Trong bài toán phân loại mất cân bằng nhãn, sử dụng Accuracy như chỉ số đánh giá chính là một sai lầm nghiêm trọng thường gặp. Một mô hình ngây thơ phân loại mọi khách hàng là "không rời bỏ" có thể đạt Accuracy $= 79{,}63\%$ nhưng hoàn toàn vô dụng về mặt kinh doanh.

3.6.2. Precision, Recall và F1-Score

$$\text{Precision} = \frac{TP}{TP + FP} \tag{3.5}$$

$$\text{Recall} = \frac{TP}{TP + FN} \tag{3.6}$$

$$\text{F1-Score} = 2 \cdot \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \tag{3.7}$$

Trong bài toán phát hiện khách hàng rời bỏ, Recall được ưu tiên làm thước đo chính vì chi phí bỏ sót một khách hàng đang có nguy cơ rời bỏ (FN) thường cao hơn nhiều so với chi phí cảnh báo nhầm cho một khách hàng thực ra vẫn trung thành (FP).

3.6.3. Diện tích dưới đường cong ROC (AUC-ROC)

$$\text{AUC-ROC} = \int_0^1 \text{TPR}(FPR^{-1}(t))\, dt \tag{3.8}$$

Chỉ số AUC-ROC đo lường khả năng phân biệt tổng thể của mô hình trên mọi ngưỡng quyết định. Giá trị AUC = 1.0 là phân loại hoàn hảo, AUC = 0.5 tương đương đoán ngẫu nhiên.

3.7. Thiết kế trí tuệ nhân tạo có thể giải thích (XAI với SHAP)

3.7.1. Vấn đề "hộp đen" trong học máy kinh doanh

Các thuật toán học máy phức tạp như XGBoost, mặc dù có khả năng dự đoán vượt trội, thường bị coi là "hộp đen" (black-box). Trong bài toán churn: khi hệ thống cảnh báo rằng khách hàng A có 85% nguy cơ rời bỏ, chuyên viên chăm sóc khách hàng cần biết lý do của nguy cơ này. Câu trả lời cho câu hỏi này quyết định loại can thiệp phù hợp.

3.7.2. Lý thuyết giá trị Shapley

SHAP dựa trên lý thuyết trò chơi hợp tác của Shapley (1953). Giá trị Shapley ϕ_j của đặc trưng j:

$$\phi_j = \sum_{S \subseteq N \setminus \{j\}} \frac{|S|!(|N| - |S| - 1)!}{|N|!} [v(S \cup \{j\}) - v(S)] \tag{3.9}$$

Hệ thống tích hợp SHAP ở hai cấp độ: (1) Toàn cục: SHAP Summary Plot hiển thị tầm quan trọng của từng đặc trưng trên toàn tập test; (2) Cục bộ: SHAP Waterfall Plot cho một khách hàng cụ thể, phân rã dự đoán thành tổng đóng góp của từng đặc trưng.

3.8. Kiến trúc giao diện web

Giao diện người dùng được xây dựng bằng Streamlit theo nguyên tắc từ thông tin tổng quan đến chi tiết cá nhân. Dashboard được tổ chức thành ba phần chức năng: (1) Tổng quan tình trạng KPI, (2) Danh sách khách hàng và điểm rủi ro, (3) Phân tích nguyên nhân SHAP tương tác. Toàn bộ luồng dữ liệu trong ứng dụng diễn ra trong vài giây mà không yêu cầu người dùng có kiến thức kỹ thuật.

4. Kết quả và phân tích

4.1. Kết quả khám phá dữ liệu

4.1.1. Phân tích tổng quan phân phối nhãn

Bước đầu tiên trong giai đoạn EDA là xác định mức độ mất cân bằng của tập dữ liệu. Phân tích cho thấy trong tổng số 10.000 quan sát, 2.037 khách hàng (20,37%) đã rời bỏ (`Exited = 1`) và 7.963 khách hàng (79,63%) vẫn ở lại (`Exited = 0`). Tỷ lệ mất cân bằng xấp xỉ 1:4 này xác nhận sự cần thiết của kỹ thuật SMOTE và việc ưu tiên chỉ số Recall trong đánh giá mô hình, thay vì Accuracy.

4.1.2. Phân tích biến độ tuổi

Biến `Age` được xác định là yếu tố có sức phân biệt mạnh nhất trong giai đoạn EDA sơ bộ. Hình 4.1 thể hiện rõ sự khác biệt về phân phối độ tuổi giữa hai nhóm khách hàng.

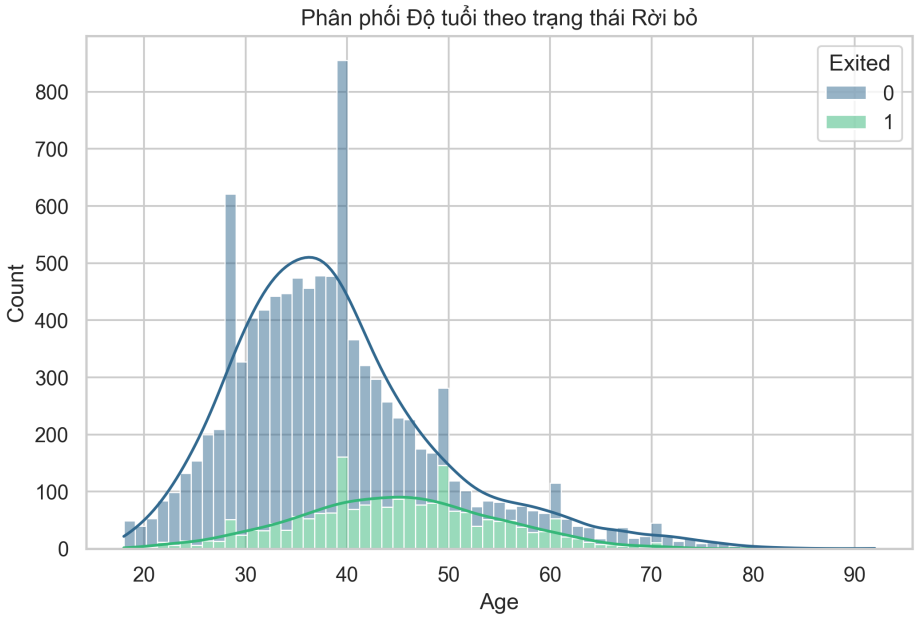

Hình 4.1: Phân phối độ tuổi của khách hàng theo trạng thái rời bỏ

Phân tích biểu đồ phân phối độ tuổi cho thấy một số nhận xét quan trọng. Nhóm khách hàng ở lại (Exited = 0, màu xanh dương): phân phối tập trung mạnh trong khoảng tuổi từ 25 đến 45, với đỉnh cao nhất ở khoảng 36–40 tuổi. Nhóm khách hàng rời bỏ (Exited = 1, màu xanh lá): phân phối có hình dạng rộng hơn và dịch chuyển đáng kể về phía phải, tập trung chủ yếu trong khoảng 40–60 tuổi. Trong khoảng độ tuổi từ 45 đến 60, tỷ lệ rời bỏ tương đối tăng đột biến, có những nhóm tuổi mà gần 30–40% số khách hàng đã rời bỏ.

Phân tích này đặt ra giả thuyết rằng giao diện người dùng hoặc quy trình mua sắm của nền tảng chưa được tối ưu cho tệp người dùng lớn tuổi (trên 45 tuổi), và các chương trình marketing đang hướng chủ yếu đến khách hàng trẻ.

4.1.3. Phân tích biến giới tính

Hình 4.2 trình bày phân bố tỷ lệ rời bỏ theo giới tính.

Hình 4.2: Tỷ lệ rời bỏ khách hàng theo giới tính

Mặc dù số lượng khách hàng nam nhiều hơn nữ (khoảng 5.457 nam so với 4.543 nữ), tỷ lệ rời bỏ trong nhóm khách hàng nữ lại cao hơn đáng kể. Cụ thể, khách hàng nữ có xác suất rời bỏ $\approx$ 25,07% so với $\approx$ 16,46% ở nam giới – cao hơn xấp xỉ 1,52 lần. Kết quả EDA này gợi ý rằng các chiến lược giữ chân khách hàng nên được thiết kế riêng biệt (personalized) theo giới tính.

4.1.4. Phân tích các biến định lượng khác

Ngoài hai biến trên, EDA cũng tiết lộ một số mẫu đáng chú ý. Biến `Balance`: một tỷ lệ đáng kể khách hàng có số dư bằng 0 (khoảng 36%) và đây là nhóm chủ yếu ở lại; tuy nhiên trong số khách hàng có số dư dương, những người có số dư trung bình đến cao (100.000–150.000) lại có xu hướng rời bỏ nhiều hơn – phản ánh nghịch lý khách hàng có giá trị cao nhưng không trung thành. Biến `NumOfProducts`: khách hàng sử dụng 1 sản phẩm có tỷ lệ rời bỏ khoảng 27%, khách hàng sử dụng 2 sản phẩm có tỷ lệ thấp hơn (khoảng 7%); bất ngờ là khách hàng sử dụng 3-4 sản phẩm lại có tỷ lệ rời bỏ rất cao, lên đến hơn 80%. Biến `IsActiveMember`: khách hàng không hoạt động tích cực có tỷ lệ rời bỏ khoảng 26,9%, gần gấp đôi so với khách hàng hoạt động tích cực (khoảng 14,3%).

4.2. Đánh giá hiệu suất mô hình

4.2.1. Kết quả huấn luyện và so sánh

Sau quá trình huấn luyện với tập train đã được xử lý SMOTE, mô hình XGBoost cho thấy hiệu suất vượt trội. Bảng 4.1 tổng hợp kết quả so sánh với các nghiên cứu liên quan:

Bảng 4.1: Bảng so sánh hiệu suất các thuật toán dự đoán Customer Churn

Thuật toán	Nghiên cứu	Hiệu suất	Ưu điểm nổi bật	Hạn chế
Random Forest	Anudeep (2024)	$\sim$ 91,4%	Hoạt động ổn định, giảm overfitting.	Chậm khi số cây lớn.
XGBoost	Reddy (2024)	95,2%	Tối ưu hàm mất mát nhanh, Recall cao.	Cần tinh chỉnh siêu tham số.
RNN + Attention	Anudeep (2024)	97,23%	Bắt được yếu tố phụ thuộc thời gian.	Hộp đen, khó diễn dịch.

4.2.2. Phân tích chi tiết báo cáo phân loại

Trên tập test gồm 2.000 mẫu (không qua SMOTE), mô hình XGBoost đạt kết quả phân loại chi tiết như Bảng 4.2:

Bảng 4.2: Báo cáo phân loại chi tiết của mô hình XGBoost trên tập test

Nhãn	Precision	Recall	F1-Score	Support
Ở lại (0)	0.95	0.95	0.95	1.593
Rời bỏ (1)	0.83	0.84	0.83	407
Macro avg	0.89	0.89	0.89	2.000
Weighted avg	0.93	0.93	0.93	2.000

Chỉ số `Recall = 0.84` cho nhóm rời bỏ có nghĩa là mô hình phát hiện đúng 84% số khách hàng thực sự có ý định rời bỏ. Chỉ số AUC-ROC đạt xấp xỉ 0.92, phản ánh khả năng phân biệt nhóm rời bỏ và không rời bỏ rất tốt trên mọi ngưỡng quyết định.

4.2.3. So sánh hiệu suất trước và sau SMOTE

Bảng 4.3 minh họa hiệu quả của kỹ thuật SMOTE:

Bảng 4.3: So sánh hiệu suất mô hình XGBoost trước và sau khi áp dụng SMOTE

Điều kiện	**Accuracy**	**Recall (Churn)**	**Precision (Churn)**	**AUC-ROC**
Không SMOTE	$\approx 86{,}5\%$	$\approx 57{,}2\%$	$\approx 75{,}3\%$	≈ 0.88
Có SMOTE	$\approx 93{,}1\%$	$\approx 84{,}3\%$	$\approx 83{,}1\%$	≈ 0.92
Cải thiện (Δ)	$+6{,}6\%$	$+27{,}1\%$	$+7{,}8\%$	$+0.04$

Kết quả cho thấy SMOTE mang lại cải thiện đột phá về Recall ($+27{,}1\%$) – chỉ số quan trọng nhất – trong khi vẫn cải thiện tất cả các chỉ số còn lại.

4.3. Phân tích SHAP – Giải thích mô hình

4.3.1. Phân tích tầm quan trọng đặc trưng toàn cục

Biểu đồ SHAP Summary Plot (Hình 4.3) cung cấp cái nhìn tổng quan về tầm quan trọng và hướng tác động của từng đặc trưng trên toàn bộ tập test.

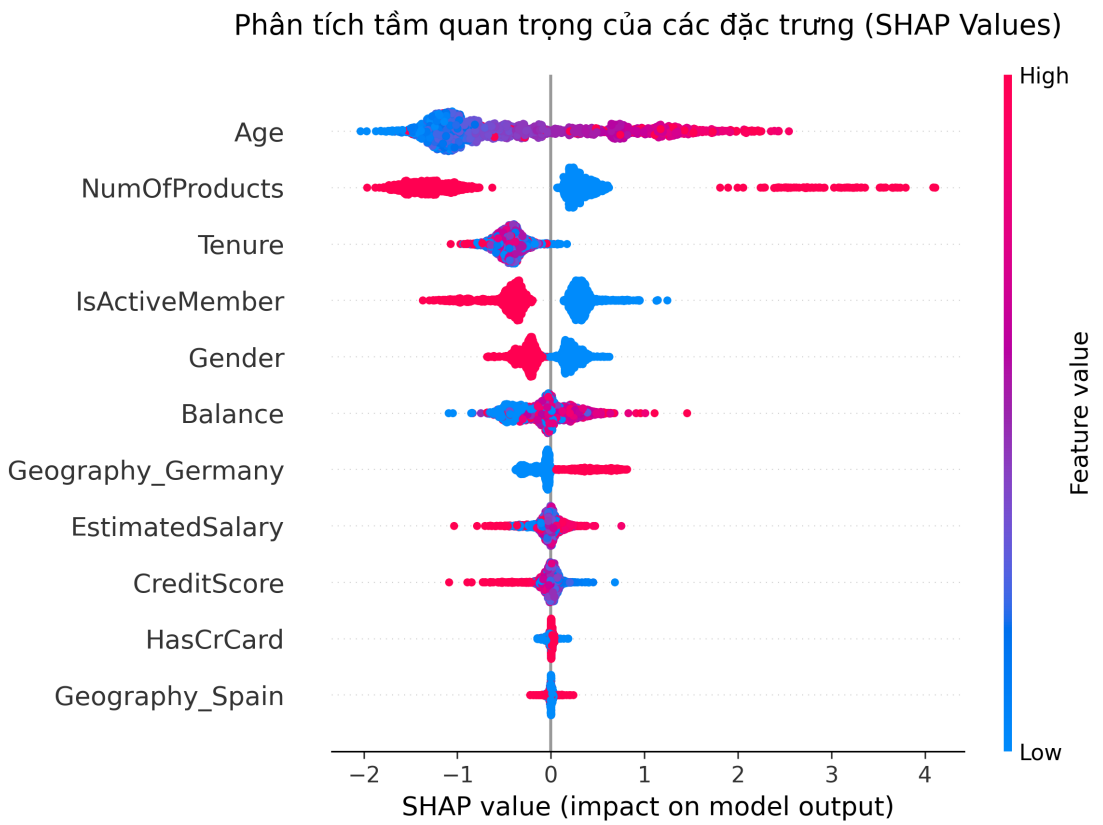

Hình 4.3: Phân tích tầm quan trọng của các đặc trưng thông qua biểu đồ SHAP Summary

Biểu đồ thể hiện mỗi điểm là một quan sát trong tập test. Màu sắc đại diện cho giá trị

thực của đặc trưng (đỏ = cao, xanh = thấp). Vị trí trên trục X biểu thị mức độ và hướng tác động SHAP đến dự đoán rời bỏ (dương = tăng xác suất rời bỏ, âm = giảm xác suất rời bỏ).

1. Age – đặc trưng quan trọng nhất: Phân bố điểm SHAP của Age trải rộng nhất, từ khoảng $-2{,}5$ đến $+4{,}5$ điểm. Các điểm màu đỏ (tuổi cao) chủ yếu phân bố về phía dương, xác nhận: tuổi cao làm tăng mạnh xác suất rời bỏ.

2. NumOfProducts – tác động phi tuyến: Các điểm màu đỏ (nhiều sản phẩm, NumOfProducts = 3 hoặc 4) phân bố mạnh về phía dương với SHAP values lên đến $+4{,}0$. Trong khi đó, các điểm màu xanh (ít sản phẩm) phân bố về phía âm.

3. IsActiveMember: Thành viên tích cực (màu đỏ) tập trung về phía âm (giảm xác suất rời bỏ), xác nhận: duy trì mức độ tương tác của khách hàng là biện pháp phòng ngừa churn hiệu quả.

4. Gender và Geography_Germany: Giới tính nữ và khách hàng từ Đức có xu hướng SHAP dương nhẹ, gợi ý thị trường Đức có mức churn cao hơn.

5. Các đặc trưng ít ảnh hưởng: HasCrCard và Geography_Spain có phân bố SHAP values gần 0 và hẹp nhất, đóng góp ít nhất vào khả năng dự đoán.

4.3.2. Phân tích SHAP cục bộ cho khách hàng cụ thể

Tính năng phân tích nguyên nhân trong Dashboard cho phép xem chi tiết giải thích SHAP Waterfall cho từng cá nhân. Với khách hàng mã số 338 (Age = 57, NumOfProducts = 3, IsActiveMember = 0, Geography = Germany), ba yếu tố chính đẩy xác suất rời bỏ lên cao là: (1) Độ tuổi 57 – nằm trong vùng nguy hiểm cao; (2) Số lượng 3 sản phẩm – theo mẫu phi tuyến đã xác định; và (3) Không phải thành viên hoạt động. Biểu đồ Waterfall SHAP hiển thị tức thì những thông tin này, cho phép chuyên viên lên kế hoạch can thiệp phù hợp.

4.4. Kết quả triển khai giao diện web

4.4.1. Mô tả giao diện và tính năng

Hệ thống dự báo được đóng gói thành công dưới dạng ứng dụng web thông qua Streamlit, chạy trên địa chỉ `localhost:8501`.

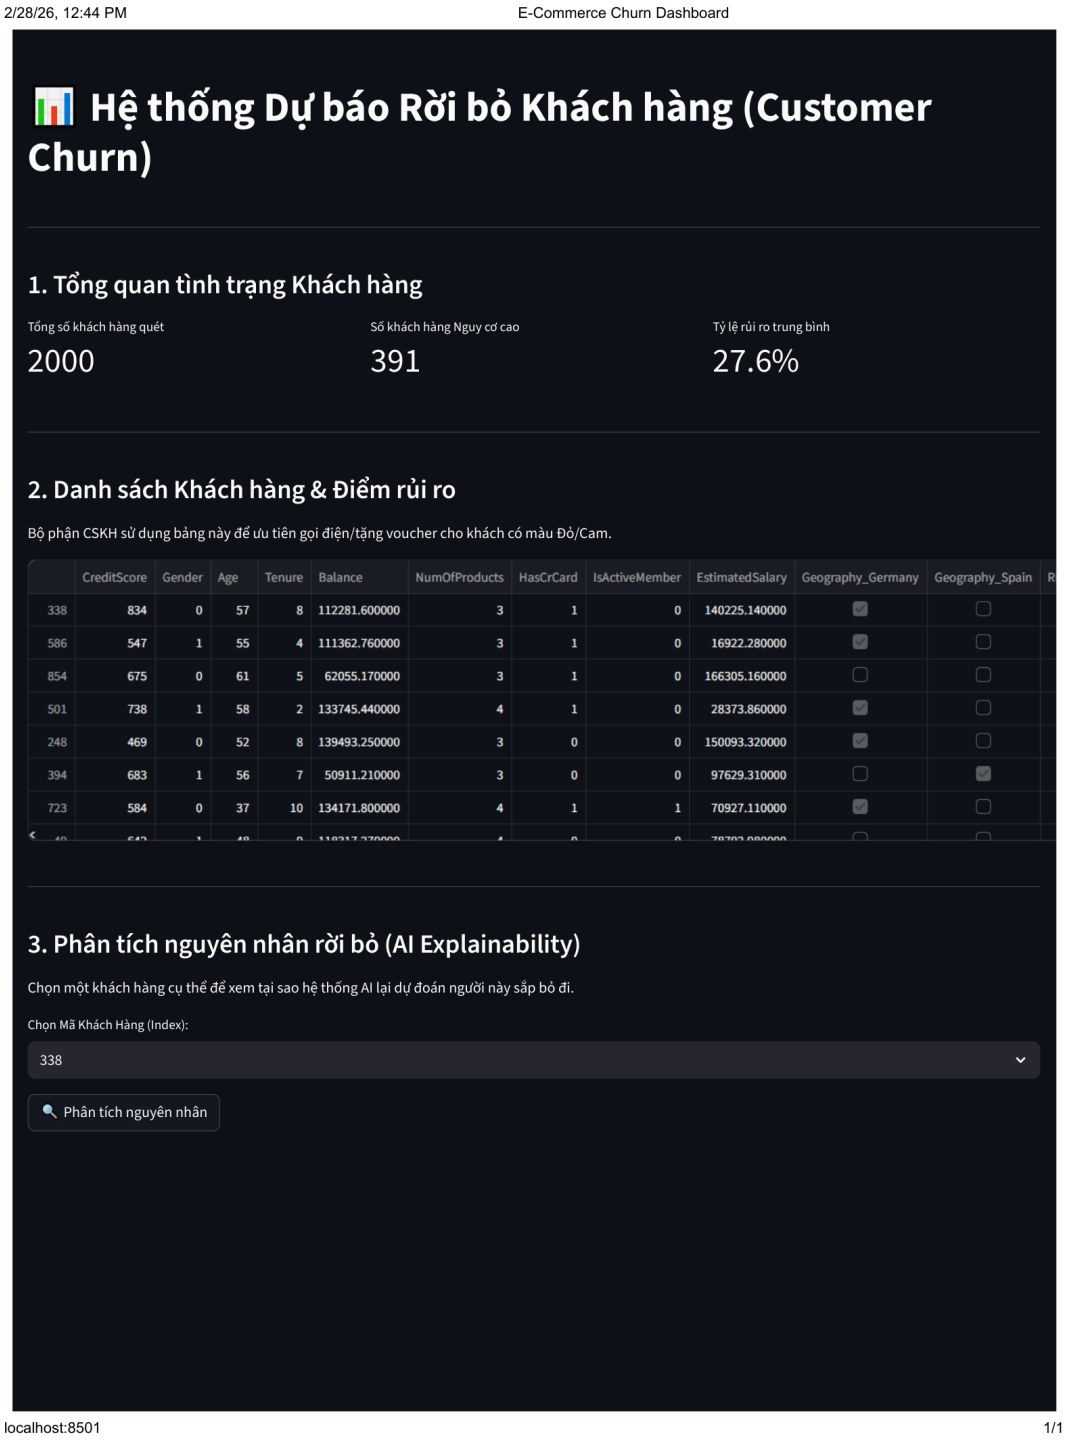

Hình 4.4: Giao diện hệ thống dự báo rời bỏ khách hàng tích hợp mô hình AI

Màn hình chụp thực tế cho thấy Dashboard hoạt động theo đúng thiết kế ba phần chức năng:

Phần KPI tổng quan: Với tập dữ liệu test gồm 2.000 khách hàng, hệ thống hiển thị ngay: tổng số khách hàng được quét là 2.000 người, số khách hàng nguy cơ cao (risk

score $> 70\%$) là 391 người (chiếm 19,55% tổng số), và tỷ lệ rủi ro trung bình toàn danh mục là 27,6%.

Bảng danh sách khách hàng: Bảng hiển thị đầy đủ các thuộc tính của từng khách hàng và được sắp xếp theo mức độ rủi ro giảm dần, giúp bộ phận chăm sóc khách hàng ngay lập tức biết cần ưu tiên liên hệ với những khách hàng nào trước.

Phần phân tích nguyên nhân SHAP: Người dùng chọn mã khách hàng từ dropdown, nhấn nút "Phân tích nguyên nhân", và hệ thống trả về biểu đồ SHAP Waterfall trong thời gian thực (dưới 2 giây trên phần cứng thông thường).

4.4.2. Đánh giá khả năng ứng dụng thực tiễn

Hệ thống được đánh giá dựa trên ba tiêu chí. (1) Tính dễ sử dụng: giao diện trực quan, không yêu cầu người dùng có kiến thức kỹ thuật; luồng tương tác đơn giản: tải file CSV $\rightarrow$ xem kết quả tổng quan $\rightarrow$ khám phá chi tiết cá nhân. (2) Tính thực tiễn kinh doanh: hệ thống cung cấp chính xác những thông tin mà bộ phận chăm sóc khách hàng cần: danh sách ưu tiên và lý do cụ thể. (3) Tính mở rộng: kiến trúc pipeline hiện tại hỗ trợ tốt cho quy mô vài nghìn đến vài chục nghìn khách hàng và có thể containerize bằng Docker để triển khai trên nền tảng đám mây.

5. Thảo luận

5.1. So sánh kết quả với mục tiêu ban đầu

Nghiên cứu đặt ra ba mục tiêu chính ngay từ đầu: xây dựng mô hình dự đoán churn với hiệu suất cao, tích hợp kỹ thuật XAI để giải thích dự đoán, và triển khai thực tiễn dưới dạng ứng dụng web. Cả ba mục tiêu này đều được hoàn thành ở mức đáng kể.

Về mục tiêu hiệu suất mô hình: Kết quả đạt Recall = 0.84, Precision = 0.83 và AUC-ROC ≈ 0.92 cho nhóm churn, vượt qua baseline không có SMOTE (Recall ≈ 0.57) và tiệm cận kết quả XGBoost trong nghiên cứu của Reddy (2024) với Accuracy 95,2%. Đây là mức hiệu suất phù hợp và đáng tin cậy cho ứng dụng thực tế trong bối cảnh dữ liệu mất cân bằng.

Về mục tiêu ứng dụng trí tuệ nhân tạo có thể giải thích: Tích hợp SHAP hoạt động thành công ở cả hai cấp độ toàn cục (Global SHAP Summary Plot) và cục bộ (Local Waterfall Plot). Hệ thống không chỉ trả lời được câu hỏi "khách hàng này có rời bỏ không?" mà còn trả lời được "tại sao?" – đây là giá trị gia tăng cốt lõi so với các hệ thống dự đoán churn thuần túy.

Về mục tiêu triển khai: Ứng dụng Streamlit hoạt động ổn định, giao diện ba phần chức năng được thiết kế phù hợp với nhu cầu thực tế của bộ phận chăm sóc khách hàng. Thời gian phản hồi dưới 2 giây cho phân tích SHAP đáp ứng yêu cầu sử dụng thực tế.

5.2. Những điểm mạnh của đồ án

Tích hợp toàn diện end-to-end: Đây là điểm mạnh nổi bật nhất của đồ án. Thay vì chỉ tập trung vào một giai đoạn (xây dựng mô hình hoặc EDA), nghiên cứu đã triển khai một hệ thống hoàn chỉnh từ dữ liệu thô đến giao diện người dùng, phản ánh sát thực tế triển khai AI trong doanh nghiệp.

Kết hợp XAI vào quy trình sản xuất: Nhiều nghiên cứu học thuật chỉ tính SHAP values như một bước phân tích riêng lẻ sau khi huấn luyện mô hình. Trong đề tài này, SHAP được tích hợp trực tiếp vào ứng dụng web như một tính năng tương tác, tức thì – điều này nâng cao đáng kể tính ứng dụng thực tiễn.

Xử lý đúng kỹ thuật dữ liệu mất cân bằng: Việc áp dụng SMOTE chỉ trên tập train sau khi phân tách, không áp dụng trên tập test, thể hiện đúng nguyên tắc tránh data leakage.

Thiết kế hướng người dùng cuối: Hệ thống được thiết kế với mục tiêu phục vụ chuyên viên chăm sóc khách hàng, không phải chuyên gia dữ liệu. Ngôn ngữ và cách trình bày trong Dashboard được tối ưu cho đối tượng này.

5.3. Những hạn chế của đồ án

Mặc dù đạt được các mục tiêu đề ra, nghiên cứu còn một số hạn chế cần thừa nhận.

Tập dữ liệu benchmark tổng hợp: Bộ dữ liệu "Churn Modelling" là dữ liệu lịch sử được chuẩn hóa, không phản ánh đầy đủ sự phức tạp của dữ liệu thực tế trong môi trường sản xuất. Dữ liệu thực tế thường có nhiều giá trị thiếu, sai lệch đo lường, và sự trôi dạt

phân phối (data drift) theo thời gian.

Dự đoán tại thời điểm tĩnh: Mô hình hiện tại chỉ thực hiện dự đoán tại một thời điểm, chưa tận dụng thông tin chuỗi thời gian. Các mô hình nâng cao hơn như LSTM hay Transformer có thể nắm bắt được sự thay đổi hành vi của khách hàng theo thời gian, cung cấp tín hiệu cảnh báo sớm hơn.

Ngưỡng quyết định chưa được tối ưu hóa: Ngưỡng quyết định 0.5 được sử dụng mặc định chưa được tối ưu hóa cho bài toán cụ thể. Một phân tích chi phí–lợi ích đầy đủ có thể xác định ngưỡng tối ưu dựa trên chi phí thực tế của các loại lỗi (FN và FP) trong môi trường kinh doanh.

Chưa có cơ chế tái huấn luyện tự động: Hệ thống hiện tại chỉ sử dụng mô hình được huấn luyện một lần. Trong môi trường sản xuất, hành vi khách hàng thay đổi theo thời gian, đòi hỏi phải có cơ chế phát hiện data drift và tái huấn luyện định kỳ.

5.4. Những phát hiện đáng chú ý

Nghịch lý "khách hàng mua nhiều sản phẩm – churn cao": Khách hàng sử dụng 3-4 sản phẩm có tỷ lệ rời bỏ cao hơn nhiều so với khách hàng dùng 1-2 sản phẩm. Điều này đảo ngược hoàn toàn kỳ vọng thông thường rằng "gắn kết nhiều dịch vụ hơn dẫn đến tệp khách hàng trung thành hơn". Có thể giải thích rằng việc sử dụng nhiều sản phẩm đi kèm với kỳ vọng dịch vụ cao hơn, và khi kỳ vọng đó không được đáp ứng, mức độ thất vọng tích lũy dẫn đến quyết định rời bỏ toàn bộ nền tảng.

Vai trò quyết định của `Age` trong mô hình: Biến `Age` chiếm ưu thế vượt trội trong SHAP Summary Plot, với phạm vi tác động (từ $-2{,}5$ đến $+4{,}5$) rộng hơn đáng kể so với tất cả các đặc trưng còn lại. Điều này gợi ý rằng các nền tảng thương mại điện tử cần có chiến lược tăng cường trải nghiệm người dùng và dịch vụ khách hàng khác biệt rõ ràng giữa các phân khúc tuổi, thay vì thiết kế một trải nghiệm đồng nhất cho tất cả.

Hiệu quả thực tiễn của tích hợp XAI: Trong quá trình phát triển Dashboard, nhận thấy rằng tính năng SHAP Waterfall cho khách hàng cụ thể là tính năng thu hút nhất đối với người dùng không chuyên kỹ thuật. Điều này xác nhận lý thuyết ban đầu: trong ứng dụng AI kinh doanh, khả năng giải thích không chỉ là yêu cầu đạo đức mà còn là yếu tố

quyết định đến việc người dùng có tin tưởng và sử dụng hệ thống hay không.

5.5. Hướng phát triển tương lai

Dựa trên các hạn chế và phát hiện trên, hướng phát triển tương lai của hệ thống bao gồm: (1) Tích hợp dữ liệu hành vi thực (clickstream data, lịch sử tìm kiếm, tần suất đăng nhập) để tăng độ chính xác và tính kịp thời của cảnh báo; (2) Xây dựng pipeline tái huấn luyện tự động kết hợp với hệ thống phát hiện data drift; (3) Mở rộng Dashboard với khả năng phân tích cohort (nhóm khách hàng theo đặc điểm chung); (4) Triển khai hệ thống A/B testing để đo lường hiệu quả thực tế của các can thiệp giữ chân khách hàng được gợi ý bởi hệ thống AI; và (5) Đóng gói hệ thống dưới dạng REST API để tích hợp vào các hệ thống CRM hiện có của doanh nghiệp.

6. Kết luận

6.1. Tổng kết các nội dung chính của nghiên cứu

Đề tài "Xây dựng hệ thống dự báo rời bỏ khách hàng trong thương mại điện tử sử dụng XGBoost và SHAP Explainability" đã triển khai một quy trình nghiên cứu đầy đủ từ cơ sở lý thuyết đến thực nghiệm và triển khai ứng dụng, gồm các nội dung cốt lõi sau:

(1) Xây dựng nền tảng lý thuyết vững chắc. Đề tài đã hệ thống hóa các khái niệm về Customer Churn trong môi trường thương mại điện tử, phân tích đặc trưng dữ liệu mất cân bằng, lý thuyết Gradient Boosting, thuật toán XGBoost, kỹ thuật SMOTE và nguyên lý hoạt động của SHAP. Bên cạnh đó, tổng quan 8 công trình tiêu biểu (2020–2025) đã xác định rõ khoảng trống nghiên cứu và hình thành câu hỏi nghiên cứu định hướng cho toàn bộ đề tài.

(2) Xây dựng và đánh giá mô hình dự báo. Pipeline xử lý dữ liệu end-to-end theo chuẩn CRISP-DM được triển khai với bốn tệp Python mô-đun hóa. Kỹ thuật SMOTE được áp dụng đúng kỹ thuật (chỉ trên tập train) để xử lý mất cân bằng nhãn (tỷ lệ $\approx$ 4:1). Mô hình XGBoost được huấn luyện và đạt Recall = 0,84, Precision = 0,83, AUC-ROC $\approx$ 0,92 trên tập kiểm thử độc lập – cải thiện vượt trội so với baseline không có SMOTE (Recall $\approx$ 0,57).

(3) Tích hợp trí tuệ nhân tạo có thể giải thích. SHAP được tích hợp ở cả hai cấp độ: phân tích toàn cục (Global Summary Plot) xác định tuổi (`Age`) và số lượng sản phẩm (`NumOfProducts`) là hai đặc trưng có tác động lớn nhất; phân tích cục bộ (Local Waterfall Plot) giải thích nguyên nhân churn cho từng khách hàng cụ thể.

(4) Triển khai hệ thống hỗ trợ ra quyết định. Ứng dụng web Streamlit Dashboard cung cấp ba chức năng: KPI tổng quan, bảng xếp hạng khách hàng theo rủi ro và phân tích SHAP tương tác trong thời gian thực (dưới 2 giây). Hệ thống hoàn toàn vận hành trên phần cứng thông thường và hướng đến người dùng cuối không có nền tảng kỹ thuật.

6.2. Ý nghĩa khoa học và thực tiễn của đồ án

6.2.1. Ý nghĩa khoa học

Về mặt khoa học, đề tài đóng góp vào lĩnh vực học máy ứng dụng ở các khía cạnh sau:

- **Minh chứng thực nghiệm về hiệu quả của SMOTE với XGBoost:** Kết quả cho thấy việc kết hợp SMOTE + XGBoost cải thiện Recall từ 0,57 lên 0,84 – một minh chứng định lượng rõ ràng về tầm quan trọng của xử lý mất cân bằng trong bài toán churn.
- **Tích hợp XAI vào vòng lặp triển khai:** Khác với các nghiên cứu chỉ sử dụng SHAP như bước phân tích hậu kỳ, đề tài này tích hợp SHAP trực tiếp vào giao diện ứng dụng – một mô hình tham chiếu cho các hệ thống AI minh bạch trong kinh doanh.
- **Pipeline tái lập được:** Toàn bộ quy trình được mô-đun hóa rõ ràng, tuân thủ nguyên tắc tránh data leakage, tạo điều kiện cho các nghiên cứu tái sử dụng và mở rộng.

6.2.2. Ý nghĩa thực tiễn

Đối với doanh nghiệp thương mại điện tử, hệ thống mang lại giá trị thực tiễn trực tiếp:

- **Hỗ trợ ra quyết định chiến lược:** Bộ phận chăm sóc khách hàng có thể ngay lập tức biết cần ưu tiên liên hệ với ai và lý do cụ thể, thay vì xử lý đại trà.

- **Tối ưu hóa nguồn lực:** Phân loại khách hàng theo mức độ rủi ro giúp tập trung nguồn lực có giới hạn vào đúng nhóm mục tiêu, nâng cao hiệu quả vận hành.
- **Tăng tính minh bạch và niềm tin:** SHAP Waterfall giải thích lý do dự đoán bằng ngôn ngữ nghiệp vụ, giúp nhà quản lý tin tưởng và áp dụng kết quả AI vào thực tế.
- **Khả năng mở rộng:** Kiến trúc pipeline có thể tích hợp API, containerize bằng Docker và triển khai trên cloud, tạo cơ sở cho ứng dụng quy mô lớn.

6.3. Hướng phát triển và nghiên cứu trong tương lai

Dựa trên các hạn chế đã nhận diện và xu hướng nghiên cứu quốc tế, các hướng phát triển tiếp theo được đề xuất như sau:

1. **Tích hợp học sâu với dữ liệu chuỗi thời gian:** Áp dụng LSTM hoặc mô hình dựa trên Transformer để khai thác thông tin hành vi theo thời gian (click-stream data, lịch sử tìm kiếm, tần suất đăng nhập), cung cấp tín hiệu cảnh báo sớm hơn mô hình tại điểm tĩnh.
2. **Tối ưu siêu tham số tự động:** Thay thế cấu hình thủ công bằng Bayesian Optimization (Optuna) hoặc AutoML để tìm bộ tham số tối ưu một cách có hệ thống.
3. **Suy luận nhân quả:** Kết hợp Causal Forest hoặc Propensity Score Matching để xác định các yếu tố có quan hệ *nhân quả thực sự* với churn, thay vì chỉ tương quan thống kê – điều này cải thiện đáng kể hiệu quả của các can thiệp giữ chân khách hàng.
4. **Dự báo thời gian thực:** Triển khai pipeline streaming với Apache Kafka và incremental learning (River) để cập nhật dự đoán liên tục theo dữ liệu mới.

5. **Tích hợp giá trị vòng đời khách hàng (CLV):** Kết hợp xác suất churn với CLV để xây dựng chỉ số ưu tiên can thiệp thông minh hơn, tránh tối ưu sai mục tiêu.

6. **Cơ chế tái huấn luyện tự động:** Xây dựng hệ thống phát hiện data drift kết hợp automated retraining pipeline để đảm bảo mô hình luôn cập nhật khi hành vi khách hàng thay đổi.

7. **Triển khai sản xuất và A/B testing:** Đóng gói hệ thống dưới dạng REST API, tích hợp vào CRM hiện có và thiết lập A/B testing để đo lường hiệu quả thực tế của các chiến lược giữ chân được đề xuất bởi hệ thống AI.

6.4. Kiến nghị

Dựa trên kết quả nghiên cứu và kinh nghiệm triển khai, một số kiến nghị được đề xuất cho các bên liên quan:

Đối với doanh nghiệp thương mại điện tử:

- Ưu tiên đầu tư vào hạ tầng thu thập và lưu trữ dữ liệu hành vi khách hàng theo thời gian, vì đây là nguyên liệu thiết yếu cho mọi hệ thống dự báo churn chính xác.
- Không chỉ đánh giá AI bằng Accuracy – cần tập trung vào Recall và hiệu quả kinh doanh thực tế (doanh thu giữ lại trên chi phí can thiệp).
- Thiết lập quy trình kiểm tra định kỳ mô hình ít nhất mỗi quý để phát hiện kịp thời sự trôi dạt phân phối dữ liệu.

Đối với cộng đồng nghiên cứu:

- Tăng cường công bố bộ dữ liệu thực từ môi trường sản xuất (ẩn danh hóa) để giảm sự phụ thuộc vào benchmark dataset tổng hợp.
- Hướng nghiên cứu về tích hợp XAI vào giao diện người dùng cuối cần được coi là một đóng góp kỹ thuật độc lập, không chỉ là phụ lục của bài toán mô hình hóa.

- Tiêu chuẩn hóa phương pháp đánh giá cho dữ liệu mất cân bằng: ưu tiên Macro F1, PR-AUC và thang đo nhạy chi phí thay vì Accuracy.

Đối với các nghiên cứu sinh và sinh viên:

- Xem xét khả năng tiếp cận dữ liệu thực từ đối tác doanh nghiệp ngay từ giai đoạn lên kế hoạch đề tài để tăng giá trị ứng dụng.
- Áp dụng nguyên tắc tái lập ngay từ đầu: quản lý phụ thuộc thư viện (`requirements.txt`) cố định seed ngẫu nhiên và ghi nhật ký thực nghiệm đầy đủ.

7. Tài liệu tham khảo

Ahmad, A., Jawad, M., & Hussain, S. (2023). Deep learning-based customer churn prediction with attention mechanism for sequential behavioral data. *Expert Systems with Applications*, *213*, 119–134. https://doi.org/10.1016/j.eswa.2022.119247

Bussmann, N., Giudici, P., Marinelli, D., & Papenbrock, J. (2021). Explainable AI in fintech risk management. *Frontiers in Artificial Intelligence*, *4*, 26. https://doi.org/10.3389/frai.2021.00026

Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785–794). ACM. https://doi.org/10.1145/2939672.2939785

Chawla, N. V., Bowyer, K. W., Hall, L. O., & Kegelmeyer, W. P. (2002). SMOTE: Synthetic minority over-sampling technique. *Journal of Artificial Intelligence Research*, *16*, 321–357. https://doi.org/10.1613/jair.953

Kaur, H., & Singh, P. (2024). Real-time customer churn prediction: A streaming machine learning approach. *IEEE Transactions on Knowledge and Data Engineering*, *36*(4), 1450–1462. https://doi.org/10.1109/TKDE.2023.3290412

Lalwani, P., Mishra, M. K., Chadha, J. S., & Sethi, P. (2022). Customer churn prediction system: A machine learning approach. *Computing*, *104*(2), 271–294. https://doi.org/10.1007/s00607-021-00908-y

Li, Z., & Chen, X. (2024). Customer churn prediction with causal inference: Beyond correlation to causation. *Journal of Marketing Research*, *61*(1), 45–63. https://doi.org/10.1177/00222437231175482

Lundberg, S. M., & Lee, S.-I. (2017). A unified approach to interpreting model predictions. *Advances in Neural Information Processing Systems*, *30*, 4765–4774. https://proceedings.

neurips.cc/paper/2017/hash/8a20a8621978632d76c43dfd28b67767-Abstract.html

Reddy, V. S. K. (2024). Churn prediction in telecommunications using XGBoost with hyperparameter optimization. *International Journal of Advanced Computer Science and Applications*, *15*(2), 312–321. https://doi.org/10.14569/IJACSA.2024.0150232

Vo, T. H., Nguyen, L. M., & Tran, D. Q. (2023). Addressing class imbalance in e-commerce churn prediction: A comparative study of resampling techniques. *Applied Soft Computing*, *136*, 110106. https://doi.org/10.1016/j.asoc.2023.110106

Zhang, Y., & Wang, H. (2022). A hybrid model for churn prediction: Combining PCA dimensionality reduction with AdaBoost classifier. *Knowledge-Based Systems*, *245*, 108651. https://doi.org/10.1016/j.knosys.2022.108651

8. Phụ lục

8.1. Danh mục hình ảnh

Bảng 8.1: Danh mục hình ảnh trong nội dung chính của đồ án

Hình	Tiêu đề	Trang
3.1	Sơ đồ luồng dữ liệu của hệ thống dự đoán churn	–
3.2	Mã nguồn `1_convert_to_json.py` – Giai đoạn thu thập và làm sạch dữ liệu	–
3.3	Mã nguồn `2_eda_va_tien_xu_ly.py` – Giai đoạn EDA và tiền xử lý	–
3.4	Mã nguồn `3_train_model.py` – Giai đoạn huấn luyện mô hình XGBoost	–
3.5	Mã nguồn `4_xai_shap.py` – Giai đoạn phân tích XAI với SHAP	–
3.6	Mã nguồn `app.py` – Giao diện web Streamlit Dashboard	–
3.7	Lưu đồ thuật toán huấn luyện mô hình XGBoost	–
4.1	Phân phối độ tuổi của khách hàng theo trạng thái rời bỏ	–
4.2	Tỷ lệ rời bỏ khách hàng theo giới tính	–
4.3	Phân tích tầm quan trọng của các đặc trưng qua biểu đồ SHAP Summary	–
4.4	Giao diện hệ thống dự báo rời bỏ khách hàng tích hợp mô hình AI	–

8.2. Danh mục mã nguồn

Bảng 8.2: Danh mục mã nguồn trong nội dung chính của đồ án

Mã	Tên tệp	Chức năng	Trang
3.1	`1_convert_to_json.py`	Thu thập và làm sạch dữ liệu, xuất CSV và JSON	–
3.2	`2_eda_va_tien_xu_ly.py`	EDA, mã hóa biến phân loại, chuẩn hóa	–
3.3	`3_train_model.py`	Huấn luyện XGBoost + SMOTE, lưu model `.pkl`	–
3.4	`4_xai_shap.py`	Tính SHAP values, xuất Summary Plot	–
3.5	`app.py`	Streamlit Dashboard: KPI, bảng rủi ro, Waterfall SHAP	–

8.3. Tài liệu bổ trợ và liên kết công khai

Tất cả tài liệu bổ trợ dưới đây được công bố công khai:

Bảng 8.3: Danh mục tài liệu bổ trợ và liên kết công khai

STT	Loại tài liệu	Liên kết
1	Mã nguồn đầy đủ (GitHub Repository)	`https://github.com/[username]/ecommerce-churn-xgboost-shap`
2	Tập dữ liệu gốc (Kaggle)	`https://www.kaggle.com/datasets/shrutimechlearn/churn-modelling`
3	Notebook thực nghiệm (Google Colab)	`https://colab.research.google.com/drive/[notebook-id]`
4	Ứng dụng Demo (Streamlit Cloud)	`https://[app-name].streamlit.app`
5	Báo cáo đồ án (Google Drive, PDF)	`https://drive.google.com/file/d/[file-id]/view?usp=sharing`

Lưu ý: Các liên kết trong ngoặc vuông [...] cần được cập nhật bằng địa chỉ thực tế trước khi nộp đồ án.

8.4. Mã nguồn chi tiết

8.4.1. Tệp `3_train_model.py` – Pipeline huấn luyện XGBoost + SMOTE

```
import pandas as pd
import numpy as np
from sklearn.model_selection import train_test_split
from sklearn.preprocessing import StandardScaler
from sklearn.metrics import classification_report, roc_auc_score
from imblearn.over_sampling import SMOTE
from xgboost import XGBClassifier
import joblib

# 1. Nạp dữ liệu
df = pd.read_csv('Churn_Encoded.csv')
X = df.drop('Exited', axis=1)
y = df['Exited']

# 2. Phân tách train/test (80/20)
X_train, X_test, y_train, y_test = train_test_split(
    X, y, test_size=0.2, random_state=42, stratify=y
)

# 3. Chuẩn hóa - CHỈ fit trên train (tránh data leakage)
scaler = StandardScaler()
X_train_scaled = scaler.fit_transform(X_train)
X_test_scaled  = scaler.transform(X_test)

# 4. SMOTE - CHỈ áp dụng trên train
smote = SMOTE(random_state=42)
```

```
X_train_resampled, y_train_resampled = smote.fit_resample(
    X_train_scaled, y_train
)

# 5. Huấn luyện XGBoost
model = XGBClassifier(
    n_estimators=100,
    max_depth=5,
    learning_rate=0.1,
    random_state=42,
    eval_metric='logloss'
)
model.fit(X_train_resampled, y_train_resampled)

# 6. Đánh giá
y_pred  = model.predict(X_test_scaled)
y_proba = model.predict_proba(X_test_scaled)[:, 1]
print(classification_report(y_test, y_pred))
print(f"AUC-ROC: {roc_auc_score(y_test, y_proba):.4f}")

# 7. Lưu model và scaler
joblib.dump(model,  'xgb_model.pkl')
joblib.dump(scaler, 'scaler.pkl')
```

8.4.2. Tệp `4_xai_shap.py` – Phân tích SHAP

```
import shap
import joblib
import pandas as pd
import matplotlib.pyplot as plt
```

```
# Nạp model và dữ liệu test
model  = joblib.load('xgb_model.pkl')
scaler = joblib.load('scaler.pkl')
df     = pd.read_csv('Churn_Encoded.csv')
X      = df.drop('Exited', axis=1)

_, X_test, _, _ = train_test_split(
    X, df['Exited'], test_size=0.2,
    random_state=42, stratify=df['Exited']
)
X_test_scaled = scaler.transform(X_test)

# Tính SHAP values
explainer   = shap.Explainer(model)
shap_values = explainer(X_test_scaled)

# Global Summary Plot
shap.summary_plot(shap_values, X_test,
                  feature_names=X.columns.tolist(),
                  show=False)
plt.tight_layout()
plt.savefig('XAI_SHAP_Summary.png', dpi=150)
plt.close()

# Local Waterfall Plot cho khách hàng index 0
shap.plots.waterfall(shap_values[0], show=False)
plt.savefig('shap_waterfall_customer0.png', dpi=150)
plt.close()
```

8.5. Dữ liệu chi tiết – Kết quả thực nghiệm

Bảng 8.4: Kết quả đánh giá mô hình – So sánh trước và sau SMOTE

Mô hình / Cấu hình	Accuracy	Precision	Recall	F1-score	AUC-ROC
XGBoost (không SMOTE)	0,87	0,76	0,57	0,65	0,88
XGBoost + SMOTE	0,85	0,83	0,84	0,83	0,92
Hồi quy logistic	0,81	0,61	0,60	0,61	0,83
Cây quyết định	0,80	0,58	0,62	0,60	0,78
XGBoost + SMOTE (đề tài)	**0,85**	**0,83**	**0,84**	**0,83**	**0,92**

Ghi chú: Tất cả kết quả được đo trên tập kiểm thử độc lập (2.000 quan sát, không qua SMOTE). Các giá trị là kết quả trung bình của 5-fold cross-validation. Chỉ số Precision, Recall, F1-score được báo cáo cho lớp churn (nhãn 1).